


最优化理论与方法

研究生学位课

陈军华（副教授、副主任）

• 求解框架

- 1、从起点 x^0 开始, 计算 $f(x^0), \nabla f(x^0), \nabla^2 f(x^0)$;
- 2、选择一个从 x^0 出发的寻优方向 d^0 ;
- 3、沿着方向 d^0 找到新点 (值) x^1 , 计算 $f(x^1), \nabla f(x^1), \nabla^2 f(x^1)$;
- 4、重复以上步骤, 产生新点 x^2, x^3, \dots , 在每步迭代中取得更优的值。



• 关键问题

- 哪个方向? 步长? 算法能保证到达最优吗? 多少步?

• 梯度法收敛性分析

- 使用最速下降法，收敛性为线性：

$$\lim_{p \rightarrow \infty} \frac{f(x^{p+1}) - f(x^*)}{f(x^p) - f(x^*)} = a < 1$$

求得局部最优，与初始点有关。

迭代次数也与初始点有关，初始点离最优值越接近越好。

二阶收敛梯度搜索算法技术

- 二次函数

- 可用正式表示:

$$f(x_1, \dots, x_n) = \frac{1}{2} \sum_{j=1}^n \sum_{i=1}^n x_j a_{ij} x_i + \sum_{i=1}^n b_i x_i + c$$

- 向量矩阵的形式为:

$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

*c*如果A为正定阵，则*f(x)*为正定二次函数。

二次函数的梯度: $\nabla f(x) = Ax + b$.

若A正定，则 *f(x)*有唯一最优解:

$$x^* = -A^{-1}b$$

- 二次函数

- $f(x) = c + b^T x + \frac{1}{2} x^T A x$, 若 $A > 0$, 则 $f(x)$ 有全局最优解, 且为: $x^* = -A^{-1}b$
- 证明:

• 二次函数

▣ $f(x) = c + b^T x + \frac{1}{2} x^T A x$, 若 $A > 0$, 则 $f(x)$ 有全局最优解, 且为: $x^* = -A^{-1}b$

▣ 证明: 构造一个函数 $\varphi(x) = \frac{1}{2} (x + A^{-1}b)^T A (x + A^{-1}b)$

$$\begin{aligned}\varphi(x) &= \frac{1}{2} (x^T + b^T A^{-1}) (Ax + b) \\&= \frac{1}{2} x^T A x + b^T x + \frac{1}{2} b^T A^{-1} b \\&= \frac{1}{2} x^T A x + b^T x + c - c + \frac{1}{2} b^T A^{-1} b \\&= f(x) - f(x^*)\end{aligned}$$

由于 $A > 0$, 当 $x \neq x^* = -A^{-1}b$ 时, $\varphi(x) > 0$. 即证。


• 共轭方向

- 设向量 $u, v \in E^n$ ，若 u, v 内积为0，即 $u^T v = (u, v) = 0$ ，则称 u 和 v 正交。
- 再设 A 为正定矩阵，若 u 和 Av 正交，即 $u^T Av = (u, Av) = 0$ ，则称 u 和 v 为 A 共轭。

▫ 推广到向量组的共轭

设 A 为正定矩阵，若非零向量组： $u^1, u^2, \dots, u^n \in E^n$ ，满足条件： $(u^i)^T A u^j = 0$ ($i \neq j, i, j = 1, 2 \dots n$)，则称该向量组为 A 共轭。当 A 为单位阵时，向量组为正交。

• 共轭



共轭：按照一定规律相配的一对。

- 共轭方向

- 定理：设 A 为正定矩阵，若非零向量组： $u^1, u^2, \dots, u^n \in E^n$ ，为 A 共轭，则该向量组线性无关。

• 共轭方向

- ▣ 定理：设 A 为正定矩阵，若非零向量组： $u^1, u^2, \dots, u^n \in E^n$ ，为 A 共轭，则该向量组线性无关。
- ▣ 证明：若线性相关，则存在不全为0的数 $a = (a_1, a_2, \dots, a_n)$ 使得：

$$a_1 u^1 + a_2 u^2 + \dots + a_n u^n = 0$$

用 $(u^i)^T A$ 左乘上式：

$$(u^i)^T A a_1 u^1 + (u^i)^T A a_2 u^2 + \dots + (u^i)^T A a_n u^n = 0$$

即： $a_i (u^i)^T A u^i = 0$

A 为正定矩阵 $u^i \neq 0$, $(u^i)^T A u^i > 0$

故： $a_i = 0$ 矛盾，即证。

- 共轭方向几何意义

- 设有二次函数

$$f(x) = \frac{1}{2} (x - \bar{x})^T A (x - \bar{x})$$

A 为 $n \times n$ 对称正定矩阵, \bar{x} 是一个定点。


则函数 $f(x)$ 的等值面: $\frac{1}{2} (x - \bar{x})^T A (x - \bar{x}) = c$

是以 \bar{x} 为中心的椭球面。

$$\because \nabla f(\bar{x}) = A(\bar{x} - \bar{x}) = 0,$$

$$\text{而 } \nabla^2 f(\bar{x}) = A > 0$$

$\therefore \bar{x}$ 是 $f(x)$ 的极小点。



设 $x^{(0)}$ 是在某个等值面上的一点, $d^{(1)}$ 是 R^n 中的一个方向,

$x^{(0)}$ 沿着 $d^{(1)}$ 以最优步长搜索得到点 $x^{(1)}$ 。

则 $d^{(1)}$ 是点 $x^{(1)}$ 所在等值面的切向量。

该等值面在点 $x^{(1)}$ 处的法向量为


$$\nabla f(x^{(1)}) = A(x^{(1)} - \bar{x}).$$

则 $d^{(1)}$ 与 $\nabla f(x^{(1)})$ 正交,

$$\text{即 } d^{(1)T} \nabla f(x^{(1)}) = 0,$$

$$\text{令 } d^{(2)} = \bar{x} - x^{(1)},$$

$$\text{所以 } d^{(1)T} A d^{(2)} = 0,$$



即等值面上一点处的切向量与由这一点指向极小点的向量关于 A 共轭。

• 共轭方向搜索的二阶收敛性

- 对于多元正定二次目标函数，从任意初始点出发，如果经过有限次迭代就能够求得极小点，那么这种算法具有二次终止性。
- 例如Newton法对于二次函数只须经过一次迭代就可以求得极小点，因此是二次终止的；而最速下降法不具有二次终止性；共轭方向法（包括共轭梯度法，变尺度法等）是二次终止的。
- 一般来说，具有二次终止性的算法，在用于一般函数时，收敛速度较快。

- 共轭方向搜索的二阶收敛性

- 定理：对于一寻优算法，若每一步寻优方向都相互共轭（即沿着共轭方向），则此算法是二阶收敛的。

证明此定理，可设 $f(x) = c + b^T x + \frac{1}{2} x^T A x$ 为正定二次函数，从任一初始点 x^0 出发，相继以 u^1, u^2, \dots, u^n 为搜索方向，其中 u^1, u^2, \dots, u^n 为 A 共轭。试证明经至多 n 次迭代后可达最优点： $x^* = -A^{-1}b$

$$\text{迭代规则是：} \begin{cases} \min_{\lambda} f(x^i + \lambda u^{i+1}) \\ x^{i+1} = (x^i + \lambda_{i+1} u^{i+1}) \end{cases}$$

- 共轭方向搜索的二阶收敛性

▣ 证明：设各次搜索点分别为： x^1, x^2, \dots, x^n

则： $x^1 = x^0 + \lambda_1 u^1$

$$x^2 = x^1 + \lambda_2 u^2 = x^0 + \lambda_1 u^1 + \lambda_2 u^2$$

....

$$x^i = x^0 + \sum_{k=1}^i \lambda_k u^k$$

考虑 $x^{i+1} = x^i + \lambda_{i+1} u^{i+1}$ ，根据迭代规则步长 λ_{i+1} 要满足：

$\min_{\lambda} f(x^i + \lambda u^{i+1})$ ，根据最速下降的条件可知相邻两方向正交：

$$(u^{i+1}, \nabla f(x^i + \lambda_{i+1} u^{i+1})) = 0$$

由于 $\nabla f(x) = Ax + b$ 代入上式可得：

- 共轭方向搜索的二阶收敛性

$$\lambda_{i+1} = -\frac{(u^{i+1}, Ax^i + b)}{(u^{i+1}, Au^{i+1})} = -\frac{(u^{i+1}, Ax^0 + b)}{(u^{i+1}, Au^{i+1})}$$

$$x^n = x^0 + \sum_{k=1}^n \lambda_k u^k = x^0 - \sum_{k=1}^n \frac{(u^k, Ax^0 + b)}{(u^k, Au^k)} u^k$$

$$= x^0 - \sum_{k=1}^n \frac{(u^k, Ax^0)}{(u^k, Au^k)} u^k - \sum_{k=1}^n \frac{(u^k, A[A^{-1}b])}{(u^k, Au^k)} u^k$$

$$= x^0 - x^0 - A^{-1}b = -A^{-1}b = x^*$$

• 共轭方向搜索的二阶收敛性

- 1) 和初始点无关;
- 2) 和共轭方向的顺序无关;
- 3) 迭代次数最多为 n ，即与维数有关。




图 5-2 二维正定二次函数的二次终结性

- 例 4_6

用共轭方向的寻优原理，求

$$\min f(x_1, x_2) = 1 + x_1 - x_2 + x_1^2 + 2x_2^2$$

• 例 4_6

用共轭方向的寻优原理，求

$$\min f(x_1, x_2) = 1 + x_1 - x_2 + x_1^2 + 2x_2^2$$

解： $A = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}$ ，构造为 A 的共轭向量，

$$u^1 = [1, 0]^T, u^2 = [0, 1]^T, \text{ 可验证 } (u^1, Au^2) = 0$$

初始点为 $x^0 = [0, 0]^T$ ，根据 $\lambda_i = -\frac{(u^i, Ax^0 + b)}{(u^i, Au^i)}$ ，可得：

$$\lambda_1 = -\frac{1}{2}, \lambda_2 = \frac{1}{4}$$

$$x^2 = x^0 + \lambda_1 u^1 + \lambda_2 u^2 = \left[-\frac{1}{2}, \frac{1}{4}\right]^T = x^*$$

- **共轭梯度算法（Conjugate-direction）**

以梯度法的求解框架，**产生一组共轭向量**。

在生成共轭向量的同时，考虑算法的效率和计算的复杂度，尽量不用二阶梯度。

算法基本思想是把**共轭性与最速下降方法**相结合，利用已知点处的梯度构造一组共轭方向，并沿这组方向进行搜索，求出目标函数的极小点。

- **Fletcher-Reeves共轭梯度算法**

- 1: 选取初始点 x^0 , 初始方向 $v^0 = -\nabla f(x^0)$

- 2: *for* $i = 1, \dots, n$

- 2.1: $x^i = x^{i-1} + \lambda_{i-1} v^{i-1}$, λ_{i-1} 取 $\min f(x^{i-1} + \lambda v^{i-1})$

- 2.2: $v^i = -\nabla f(x^i) + \frac{\|\nabla f(x^i)\|^2}{\|\nabla f(x^{i-1})\|^2} v^{i-1}$

- 3: $x^0 = x^n$.

- **Fletcher-Reeves共轭梯度-共轭向量组构造**

这里用正定二次函数说明： $f(x) = c + b^T x + \frac{1}{2} x^T A x$, $A > 0$, 初始点 x^0 , 如何构造一组共轭向量 v^0, v^1, \dots, v^{n-1}

根据算法： $v^0 = -\nabla f(x^0)$

沿 $x^0 + \lambda v^0$ 射线进行搜索， $x^1 = x^0 + \lambda v^0$,

$$\nabla f(x^1)^T v^0 = -\nabla f(x^1)^T \nabla f(x^0) = 0$$

即 x^0, x^1 两点的梯度正交，在此正交系构成的二维空间中寻找下一个方向 v^1 ，则 $v^1 = -\nabla f(x^1) + a_0 \nabla f(x^0)$

要使 v^0, v^1 为 A 共轭，则有： $v^1 A v^0 = 0$

- Fletcher-Reeves共轭梯度-共轭向量组构造**

对于二次函数有：

$$\begin{aligned}\nabla f(x^{k+1}) - \nabla f(x^k) &= Ax^{k+1} + b - Ax^k - b \\ &= A(x^{k+1} - x^k) = A(x^k + \lambda_k v^k - x^k) \\ &= \lambda_k A v^k\end{aligned}$$

由于 $v^1 A v^0 = 0$, 即 $v^1 \lambda_0 A v^0 = 0$, 展开可得：

$$\begin{aligned}v^1 \lambda_0 A v^0 &= [-\nabla f(x^1) + a_0 \nabla f(x^0)]^T [\nabla f(x^1) - \nabla f(x^0)] \\ &= -\nabla f(x^1)^T \nabla f(x^1) + a_0 \nabla f(x^0)^T \nabla f(x^1) + \nabla f(x^1)^T \nabla f(x^0) - \\ &a_0 \nabla f(x^0)^T \nabla f(x^0) = 0\end{aligned}$$

$$\text{即 } a_0 \nabla f(x^0)^T \nabla f(x^0) = -\nabla f(x^1)^T \nabla f(x^1)$$

$$a_0 = -\frac{\nabla f(x^1)^T \nabla f(x^1)}{\nabla f(x^0)^T \nabla f(x^0)} = -\frac{\|\nabla f(x^1)\|^2}{\|\nabla f(x^0)\|^2}$$

- Fletcher-Reeves共轭梯度-共轭向量组构造**

沿 $x^1 + \lambda v^1$ 射线进行搜索, $x^2 = x^1 + \lambda v^1$,

求得: $\nabla f(x^2)$

$$\begin{aligned} \text{考查式子: } & -\nabla f(x^0)^T (\nabla f(x^2) - \nabla f(x^1)) \\ &= -\nabla f(x^0)^T (\lambda_1 A v^1) \\ &= -\lambda_1 v^0 A v^1 \end{aligned}$$

由于 v^0, v^1 共轭, 故 $-\nabla f(x^0)^T (\nabla f(x^2) - \nabla f(x^1)) = 0$, 即:

$$\nabla f(x^0)^T \nabla f(x^2) = 0$$

即 x^0, x^1, x^2 三点的梯度构成三维正交系, 寻找下一个方向 v^2 ,
则 $v^2 = -\nabla f(x^1) + a_0 \nabla f(x^0) + a_1 \nabla f(x^1)$

要使 v^0, v^1, v^2 为 A 共轭, 则有: $v^2 A v^0 = 0, v^2 A v^1 = 0$

- Fletcher-Reeves共轭梯度-共轭向量组构造**

$$\lambda_0 v^2 A v^0$$

$$= [-\nabla f(x^2) + a_0 \nabla f(x^0) + a_1 \nabla f(x^1)]^T [\nabla f(x^1) - \nabla f(x^0)] = 0$$

$$\lambda_1 v^2 A v^1$$

$$= [-\nabla f(x^2) + a_0 \nabla f(x^0) + a_1 \nabla f(x^1)]^T [\nabla f(x^2) - \nabla f(x^1)] = 0$$

$$\text{求得: } a_1 = -\frac{\nabla f(x^2)^T \nabla f(x^2)}{\nabla f(x^1)^T \nabla f(x^1)} = -\frac{\|\nabla f(x^2)\|^2}{\|\nabla f(x^1)\|^2}$$

$$a_0 = a_1 \cdot \frac{\nabla f(x^1)^T \nabla f(x^1)}{\nabla f(x^0)^T \nabla f(x^0)} = a_1 \cdot \frac{\|\nabla f(x^1)\|^2}{\|\nabla f(x^0)\|^2}$$

.....

- 例 4_7

用FR共轭梯度法求：

$$\min f(x_1, x_2) = \frac{3}{2}x_1^2 + \frac{1}{2}x_2^2 - x_1x_2 - 2x_1, x^0 = (-2, 4)$$

• 例 4_7

用FR共轭梯度法求：

$$\min f(x_1, x_2) = \frac{3}{2}x_1^2 + \frac{1}{2}x_2^2 - x_1x_2 - 2x_1, x^0 = (-2, 4)$$

解：第1次迭代

$$\nabla f(x^0) = (3x_1 - x_2 - 2, x_2 - x_1)^T = (-12, 6)^T$$

$$v^0 = -\nabla f(x^0) = (12, -6)^T$$

$$x^1 = x^0 + \lambda v^0 = (-2, 4)^T + (12\lambda, -6\lambda)^T = (-2 + 12\lambda, 4 - 6\lambda)^T$$

$$f(x^1) = \frac{3}{2}(-2 + 12\lambda)^2 + \frac{1}{2}(4 - 6\lambda)^2 - (-2 + 12\lambda)(4 - 6\lambda) - 2(-2 + 12\lambda)$$

$$f'_\lambda(x^1) = 612\lambda - 180 = 0$$

$$\lambda = \frac{5}{17}, x^1 = \left(\frac{26}{17}, \frac{38}{17}\right)^T$$

• 例 4_7

第1次迭代

$$x^1 = \left(\frac{26}{17}, \frac{38}{17}\right)^T$$

$$\nabla f(x^1) = (3x_1 - x_2 - 2, x_2 - x_1)^T = \left(\frac{6}{17}, \frac{12}{17}\right)^T$$

$$v^1 = -\nabla f(x^1) + \frac{\|\nabla f(x^1)\|^2}{\|\nabla f(x^0)\|^2} d^0$$

$$= -\left(\frac{6}{17}, \frac{12}{17}\right)^T + \frac{\left\|\left(\frac{6}{17}, \frac{12}{17}\right)^T\right\|^2}{\|(-12, 6)^T\|^2} \cdot (12, -6)^T = \left(-\frac{90}{289}, -\frac{210}{289}\right)^T$$

• 例 4_7

第2次迭代

$$x^2 = x^1 + \lambda v^1 = \left(\frac{26}{17}, \frac{38}{17}\right)^T + \left(-\frac{90\lambda}{289}, -\frac{210\lambda}{289}\right)^T$$

$$\lambda = \frac{17}{10}$$

$$x^2 = (1, 1)^T$$

$$\nabla f(x^2) = 0$$

已达最优。

• 例 4_8

用**FR**共轭梯度法求：

$$\min f(x) = \frac{1}{2} x^T A x$$

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}, x^0 = (-10, 5)$$

$$x^* = (0, 0)$$

• 例 4_8

$$\nabla f(x) = \begin{pmatrix} x_1 + x_2 \\ x_1 + 2x_2 \end{pmatrix}$$

$$v^0 = -\nabla f(x) = \begin{bmatrix} 5 \\ 0 \end{bmatrix}$$

$$f(x^0 + \lambda v^0) = \frac{1}{2} (50 - 50\lambda + 25\lambda^2) \rightarrow \lambda_0 = 0.9996$$

$$x^1 = x^0 + \lambda_0 v^0 = [-5.002, 5]^T$$

$$v^1 = -\nabla f(x^1) + \frac{\|\nabla f(x^1)\|^2}{\|\nabla f(x^0)\|^2} v^0 = [4.9980, -4.9980]^T$$

$$f(x^1 + \lambda v^1) = \frac{1}{2} (26.55 - 38.95\lambda + 14.45\lambda^2) \rightarrow \lambda_1 = 1.0005$$

$$x^2 = x^1 + \lambda_1 v^1 = [-0.0016, -0.0004]^T$$

非二次函数的共轭梯度法

• 非二次函数的共轭梯度法

- 将二次函数的共轭梯度法推广到一般函数，实际上是基于对函数的二次逼近。
- 设 $f(x)$ 是定义在某一凸集 \mathbf{R} 上的二阶连续可微的严格凸函数，则在 \mathbf{R} 内有唯一极小点 x^* ，在 \mathbf{R} 内任取初始近似点 x^0
取： $v^0 = -\nabla f(x^0)$ 为初始搜索方向
则： $x^1 = x^0 + \lambda v^0$
- 对 $f(x^0 + \lambda v^0)$ 在 x^0 点作泰勒展开得：

$$f(x^0 + \lambda v^0) = f(x^0) + \lambda \nabla f(x^0)^T \cdot v^0 + \frac{1}{2} \lambda^2 v^0 H v^0 + o(\lambda^2)$$

$$\frac{df(x^0 + \lambda v^0)}{d\lambda} = \nabla f(x^0)^T \cdot v^0 + \frac{2}{2} \lambda (v^0)^T H v^0 = 0$$

- 非二次函数的共轭梯度法

$$\lambda^0 = -\frac{\nabla f(x^0)^T \cdot v^0}{(v^0)^T H v^0}$$

即为近似最优解。

现构造向量 $v^1 = -\nabla f(x^1) + \beta_0 v^0$ 使其满足共轭条件：

$$(v^1)^T H v^0 = 0$$

即：

$$(-\nabla f(x^1) + \beta_0 v^0)^T H (v^0) = 0$$

$$\beta_0 = \frac{\nabla f(x^1)^T H \cdot v^0}{(v^0)^T H v^0}$$

- 非二次函数的共轭梯度法

这就确定了 v^1 ，进而确定 x^2

如此，可连续构造方向并继续迭代，若至 k 步，有：


$$\left\{ \begin{array}{l} \begin{array}{l} x^{k+1} = x^k + \lambda^k v^k \\ \lambda^k = -\frac{\nabla f(x^k)^T \cdot v^k}{(v^k)^T H(x^k) v^k} \end{array} \\ \begin{array}{l} v^{k+1} = -\nabla f(x^{k+1}) + \beta_k v^k \\ \beta_k = \frac{\nabla f(x^{k+1})^T H(x^k) v^k}{(v^k)^T v^k} \end{array} \end{array} \right.$$

注意：由于推导中应用了近似公式，严格说来，各方向是不共轭的，这就是说， n 步收敛是不可能的。

• 非二次函数的共轭梯度法

▣ 作业：设计算法并实现 对非二次（高次）函数的寻优。

▣ 求： $\min f(x_1, x_2) = \frac{3}{2}x_1^4 + \frac{1}{2}x_2^2 - x_1x_2 - 2x_1$, $x^0 = (-2, 4)$, 精度 0.01



• 共轭梯度法特点

- 具有全局收敛性
- 收敛速度快（二次收敛）。对于正定二次函数，具有二次终结性。
- 算法结构简单，计算量小，存储量小。（如FR法只要3个n维向量的存储空间）
- 适用性：特别适用于大规模优化问题的求解。
- 共轭梯度法需要计算梯度，这个过程很耗时。

• 共轭梯度法

- 共轭梯度法需要计算梯度，这个过程很耗时。
- **Powell** 设计了通过一维搜索找到共轭方向的方法。

• Powell 算法思想

- 该方法主要由 **基本搜索**、**加速搜索**和**调整搜索**方向三个部分组成。
- 基本搜索包括从基点出发沿着已知的 n 个搜索方向进行一维搜索，确定一个新基点。
- 加速搜索是指沿着相邻的两个基点的连线方向进行一维搜索，使函数值下降更快。
- 最后用基点连续方向代替已知的 n 个搜索方向之一，构成新的搜索方向组，进行下一轮迭代。

• Powell 算法

- 设有一组线性独立的向量 $\{v^i, i = 1, \dots, n\}$, x^0 为初始点。算法步骤为:
- 1: **for** $i=1, \dots, n$, 找到 $\min_{\lambda} f(y^{i-1} + \lambda v^i)$, 的 λ 值, 递推下一点
 $y^i = y^{i-1} + \lambda v^i$
- 2: **for** $i=1, \dots, n$, 使 $v^i = v^{i+1}$
- 3: $v^n = y^n - y^0$
- 4: 找到 $\min_{\lambda} f(x^n + \lambda(x^n - x^0))$, 的 λ 值, 替换 $x^0 = y^n + \lambda(y^n - y^0)$
- 5: 达不到精度回到step1

• 例 4_9

用powell方法求 $\min f(x) = (x_1 + x_2)^2 + (x_1 - 1)^2$, 初始点

$x^0 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$, 初始搜索方向 $d^{(1,1)} = (1,0)^T$, $d^{(1,2)} = (0,1)^T$

• 例 4_9

用powell方法求 $\min f(x) = (x_1 + x_2)^2 + (x_1 - 1)^2$, 初始点

$x^0 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$, 初始搜索方向 $d^{(1,1)} = (1,0)^T$, $d^{(1,2)} = (0,1)^T$

解: 第一轮迭代:

令 $y^{(1,1)} = x^0$ 。从 $y^{(1,1)}$ 出发沿着方向 $d^{(1,1)}$ 作一维搜索。

$$\min_{\lambda} f(y^{(1,1)} + \lambda d^{(1,1)})$$

$$y^{(1,1)} + \lambda d^{(1,1)} = (2,1)^T + \lambda(1,0)^T = (2 + \lambda, 1)^T$$

$$\varphi(\lambda) = f(y^{(1,1)} + \lambda d^{(1,1)}) = (3 + \lambda)^2 + (1 + \lambda)^2$$

$$\frac{d\varphi}{d\lambda} = 2(3 + \lambda) + 2(1 + \lambda) = 0, \lambda_1 = -2$$

$$y^{(1,2)} = x^{(1,1)} + \lambda_1 d^{(1,1)} = (0,1)^T$$

• 例 4_9

从 $\mathbf{y}^{(1,2)}$ 出发沿着方向 $\mathbf{d}^{(1,2)}$ 作一维搜索。

$$\min_{\lambda} f(\mathbf{y}^{(1,2)} + \lambda \mathbf{d}^{(1,2)})$$

$$\lambda_2 = -1, \mathbf{y}^{(1,3)} = \mathbf{y}^{(1,2)} + \lambda_2 \mathbf{d}^{(1,2)} = (0,0)^T \quad (\text{坐标轮换结束})$$

$$\text{创建方向 } \mathbf{d}^{(1,3)} = \mathbf{y}^{(1,3)} - \mathbf{y}^{(1,1)} = (-2, -1)^T$$

$$\text{求解 } \min_{\lambda} f(\mathbf{x}^{(1,2)} + \lambda \mathbf{d}^{(1,3)})$$

$$\lambda_3 = -\frac{2}{13}, \mathbf{x}^1 = \mathbf{y}^{(1,3)} + \lambda_3 \mathbf{d}^{(1,3)} = (\frac{4}{13}, \frac{2}{13})^T$$

进入第2轮搜索：

$$\text{初始点 } \mathbf{y}^{(2,1)} = \mathbf{x}^1 = (\frac{4}{13}, \frac{2}{13})^T,$$

搜索方向为：

$$\mathbf{d}^{(2,1)} = \mathbf{d}^{(1,2)} = (0,1)^T, \mathbf{d}^{(2,2)} = \mathbf{d}^{(1,3)} = (-2, -1)^T$$

• 例 4_9

求解 $\min_{\lambda} f(\mathbf{y}^{(2,1)} + \lambda \mathbf{d}^{(2,1)})$

$$\lambda_1 = \frac{-6}{13}, \quad \mathbf{y}^{(2,2)} = \mathbf{y}^{(2,1)} + \lambda_1 \mathbf{d}^{(2,1)} = \left(\frac{4}{13}, \frac{-4}{13}\right)^T$$

求解 $\min_{\lambda} f(\mathbf{y}^{(2,2)} + \lambda \mathbf{d}^{(2,2)})$


$$\lambda_2 = \frac{-18}{169}, \quad \mathbf{y}^{(2,3)} = \mathbf{y}^{(2,2)} + \lambda_2 \mathbf{d}^{(2,2)} = \left(\frac{88}{169}, \frac{-34}{169}\right)^T$$

创建方向 $\mathbf{d}^{(2,3)} = \mathbf{y}^{(2,3)} - \mathbf{y}^{(2,1)} = \left(\frac{36}{169}, \frac{-60}{169}\right)^T$

求解 $\min_{\lambda} f(\mathbf{y}^{(2,3)} + \lambda \mathbf{d}^{(2,3)})$


$$\lambda_3 = \frac{9}{4}, \quad \mathbf{x}^2 = \mathbf{y}^{(2,3)} + \lambda_3 \mathbf{d}^{(2,3)} = (1, -1)^T$$

• 例 4_9 迭代过程



- 关于powell算法的共轭方向

- 定理：设 $f(x) = \frac{1}{2}x^T Ax + b^T x + c$ ， A 为 n 阶正定阵。任取方向 d 和点 x^1, x^2 。从 x^1 出发沿方向 d 作一维搜索得极小点 y^1 ，从 x^2 出发沿方向 d 作一维搜索得极小点 y^2 ，则有 $y^2 - y^1$ 与方向 d 关于 A 共轭。



• 关于powell算法的共轭方向

- 对例4_5分析共轭方向

- 第一轮搜索方向:

$$\mathbf{d}^{(1,1)} = (1,0)^T, \mathbf{d}^{(1,2)} = (0,1)^T, \quad \mathbf{d}^{(1,3)} = (-2, -1)^T$$

- 第二轮搜索方向:

$$\mathbf{d}^{(2,1)} = (0,1)^T, \mathbf{d}^{(2,2)} = (-2, -1)^T, \quad \mathbf{d}^{(2,3)} = \left(\frac{36}{169}, \frac{-60}{169}\right)^T$$

沿方向 $\mathbf{d}^{(1,3)}$ 得 \mathbf{x}^1 , 沿方向 $\mathbf{d}^{(2,2)}$ 得 $\mathbf{x}^{(2,2)}$, 而 $\mathbf{d}^{(2,3)} = \mathbf{x}^{(2,2)} - \mathbf{x}^{(2,0)}$, 故和方向 $\mathbf{d}^{(2,2)}$ 共轭。

而 \mathbf{x}^2 是沿共轭方向搜索得到的, 因此必为极小点。

- 例 4_10

- 求 $\min f(x) = x_1^2 + 2x_2^2$, $d^1 = [1, -1]^T$, $d^2 = [1, 1]^T$,
 $x^0 = [20, 20]^T$

• 例 4_10

▫ 求 $\min f(x) = x_1^2 + 2x_2^2$, $d^1 = [1, -1]^T$, $d^2 = [1, 1]^T$,
 $x^0 = [20, 20]^T$

解：第一轮迭代：

令 $y^{(1,1)} = x^0$ 。从 $y^{(1,1)}$ 出发沿着方向 $d^{(1,1)}$ 作一维搜索。

$$\min_{\lambda} f(y^{(1,1)} + \lambda d^{(1,1)})$$

$$y^{(1,1)} + \lambda d^{(1,1)} = (20, 20)^T + \lambda(1, -1)^T = (20 + \lambda, 20 - \lambda)^T$$

$$\varphi(\lambda) = f(y^{(1,1)} + \lambda d^{(1,1)}) = 3 \times (20 + \lambda)^2$$

$$\frac{d\varphi}{d\lambda} = 60(20 + \lambda) = 0, \lambda_1 = -20$$

$$y^{(1,2)} = x^{(1,1)} + \lambda_1 d^{(1,1)} = (0, 0)^T$$

• 例 4_10

从 $\mathbf{y}^{(1,2)}$ 出发沿着方向 $\mathbf{d}^{(1,2)}$ 作一维搜索。

$$\min_{\lambda} f(\mathbf{y}^{(1,2)} + \lambda \mathbf{d}^{(1,2)})$$

$$\lambda_2 = 0, \quad \mathbf{y}^{(1,3)} = \mathbf{y}^{(1,2)} + \lambda_2 \mathbf{d}^{(1,2)} = (0, 0)^T \quad (\text{坐标轮换结束})$$

$$\text{创建方向 } \mathbf{d}^{(1,3)} = \mathbf{y}^{(1,3)} - \mathbf{y}^{(1,1)} = (-20, -20)^T$$

$$\text{求解 } \min_{\lambda} f(\mathbf{x}^{(1,2)} + \lambda \mathbf{d}^{(1,3)})$$

$$\lambda_3 = 0, \quad \mathbf{x}^1 = \mathbf{y}^{(1,3)} + \lambda_3 \mathbf{d}^{(1,3)} = (0, 0)^T$$

• 例4_10

$$f(x) = x_1^2 + 2x_2^2 \quad v^1 = [1, -1]^T, \quad v^2 = [1, 1]^T, \quad x^0 = [20, 20]^T$$

$$\lambda_1 = 6.66, x^1 = x^0 + \lambda_1 v^1 = [26.66, 13.34]^T$$

$$\lambda_2 = -17.8, x^2 = x^1 + \lambda_2 v^2 = [8.86, -4.46]^T$$

$$u^1 = x^2 - x^0 = [-11.14, -24.46]^T$$

$$\lambda_3 = -0.15, x^3 = x^2 + \lambda_3 u^1 = [10.48, -0.92]^T$$

$$\lambda_4 = -3.46, x^4 = x^3 + \lambda_4 v^2 = [7.02, -4.18]^T$$

$$\lambda_5 = -0.15, x^5 = x^4 + \lambda_5 u^1 = [8.68, -0.64]^T$$

$$u^2 = x^5 - x^3 = [-1.8, 0.28]^T$$

$$(u^1, Au^2) = [-11.14, -24.46] \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} -1.8 \\ 0.28 \end{bmatrix} = 3 \neq 0$$

• powell算法运行条件

- 在此算法中，保持 n 个搜索方向线性无关十分重要。然而，Powell本人也注意到，他的方法可能选取接近线性相关的搜索方向，特别是变量很多时更是如此。这种可能性会给收敛性带来严重后果。
- 为解决这个问题，提出了改进的powell算法。
- 改进的算法，当初始搜索方向线性无关时，能够保证每轮迭代中以搜索方向为列的行列式不为零，因此这些方向是线性无关的。而且随着迭代的延续，搜索方向接近共轭的程度逐渐增加。
- 改进的powell算法不再具有二次终止性，但是，它的计算效果仍然令人满意。

- 在牛顿法基础上的改进思路

- 1: 采用共轭方向

共轭梯度算法

powell算法

- 2: 采用线性逼近

变尺度法（**DFP**算法）

• 变尺度法

- 在牛顿法中，对于二次函数，是以方向 $d^k = -H^{-1}\nabla f(x^k)$ 为寻优方向的。这种方向要求二阶逆，效率不高。
- $$\nabla f(x^0) = \nabla f(x^*) + H(x^*)(x^0 - x^*)$$
$$x^* = x^0 - H(x^*)^{-1}\nabla f(x^0)$$
- 变尺度法是构造另一个矩阵 $\bar{H}(x)$ ，用它来逼近二阶导数矩阵的逆 H^{-1} ，此法也称**拟牛顿法**。根据构造矩阵的方法不同，派生出不同的变尺度，这里介绍**DFP法**，即**Davidon-Fletcher-Powell法**。

• 变尺度算法 (DFP)

- x^i 为搜索点, H_i 为 H 阵的近似。 $g^i = \nabla f(x^i)$
- 1: 选取 x^0, H_0
- 2: for $i=0,1,\dots,n-1$

$$x^{i+1} = x^i + \lambda_i v^i, \text{ 其中 } v^i = -H_i g^i, \lambda_i \text{ 为一维搜索最优步长, } \min_{\lambda} f(x^i + \lambda v^i)$$
- 3: 令 $u^i = x^{i+1} - x^i$, $y^i = g^{i+1} - g^i$,

$$H_{i+1} = H_i + A_i - B_i, A_i = \frac{u^i (u^i)^T}{(u^i)^T y^i}, B_i = \frac{H_i y^i (H_i y^i)^T}{(y^i)^T H_i y^i}$$
- 4: 判断精度, 不满足则 $x^0 = x^n$, 转2.

- 变尺度法-拟牛顿条件

- $\bar{H}(x)$ 构造原则是：它是一阶梯度 $\nabla f(x^k)$ 的函数，且接近各搜索点的 $[\nabla^2 f(x^k)]^{-1}$ ，对于二次函数，我们有：

$$\begin{aligned}\nabla f(x^{k+1}) - \nabla f(x^k) &= A(x^{k+1} - x^k) \\ x^{k+1} - x^k &= A^{-1}[\nabla f(x^{k+1}) - \nabla f(x^k)]\end{aligned}$$

仿二次函数有：

$$x^{k+1} - x^k = \bar{H}^{k+1}[\nabla f(x^{k+1}) - \nabla f(x^k)] \quad (1)$$

上式即为拟牛顿条件。

• 变尺度法-DFP算子

$$x^{k+1} - x^k = \bar{H}^{k+1} [\nabla f(x^{k+1}) - \nabla f(x^k)]$$

令：

$$y^k = \Delta g^k = \nabla f(x^{k+1}) - \nabla f(x^k)$$

$$u^k = \Delta X^k = x^{k+1} - x^k$$

$$x^{k+1} - x^k = \bar{H}^{k+1} y^k = u^k$$

现假设 \bar{H}^k 已知，则有：

$$\bar{H}^{k+1} = \bar{H}^k + \Delta \bar{H}^k$$

$\Delta \bar{H}^k$ 为第k次校正矩阵，并应满足拟牛顿条件：

- 变尺度法-DFP算子

$$u^k = \bar{H}^{k+1} y^k$$

$$u^k = (\bar{H}^k + \Delta \bar{H}^k) y^k = \bar{H}^k y^k + \Delta \bar{H}^k y^k$$

$$\Delta \bar{H}^k y^k = u^k - \bar{H}^k y^k \quad (2)$$

设 $\Delta \bar{H}^k = u^k \cdot (Q^k)^T - \bar{H}^k y^k \cdot (W^k)^T$ (Q^k, W^k 为待定向量)

则应满足:

$$(Q^k)^T y^k = 1$$

$$(W^k)^T u^k = 1$$

$\Delta \bar{H}^k$ 为对称阵, 简单的方法是取:

- 变尺度法-DFP算子

$$Q^k = \mu_k u^k \qquad W^k = \varepsilon_k \bar{H}^k y^k$$

如此:

$$(\mu_k u^k)^T y^k = 1$$

$$(\varepsilon_k \bar{H}^k y^k)^T y^k = 1$$

$$\mu_k = \frac{1}{(u^k)^T y^k}$$

$$\varepsilon_k = \frac{1}{(y^k)^T \bar{H}^k y^k}$$

- 变尺度法-DFP算子

$$\begin{aligned}
 \Delta \bar{H}^k &= \mathbf{u}^k \cdot (\mathbf{Q}^k)^T - \bar{H}^k \mathbf{y}^k \cdot (\mathbf{W}^k)^T \\
 &= \mathbf{u}^k \cdot (\mu_k \mathbf{u}^k)^T - \bar{H}^k \mathbf{y}^k \cdot (\varepsilon_k \bar{H}^k \mathbf{y}^k)^T \\
 &= \frac{\mathbf{u}^k \cdot (\mathbf{u}^k)^T}{(\mathbf{u}^k)^T \mathbf{y}^k} - \frac{\bar{H}^k \mathbf{y}^k \cdot (\bar{H}^k \mathbf{y}^k)^T}{(\mathbf{y}^k)^T \bar{H}^k \mathbf{y}^k}
 \end{aligned}$$

为 n 阶对称阵，由分母不为零。

$$\begin{aligned}
 \bar{H}^{k+1} &= \bar{H}^k + \Delta \bar{H}^k \\
 &= \bar{H}^k + \frac{\mathbf{u}^k \cdot (\mathbf{u}^k)^T}{(\mathbf{u}^k)^T \mathbf{y}^k} - \frac{\bar{H}^k \mathbf{y}^k \cdot (\bar{H}^k \mathbf{y}^k)^T}{(\mathbf{y}^k)^T \bar{H}^k \mathbf{y}^k} \quad (3)
 \end{aligned}$$

• 例 4_11

用DFP方法求 $\min f(x) = \frac{1}{2}x^T Ax$, $A = \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix}$, $x^0 = \begin{pmatrix} 10 \\ 10 \end{pmatrix}$,

$$H_0 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

• 例 4_11

用DFP方法求 $\min f(x) = \frac{1}{2}x^T Ax$, $A = \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix}$, $x^0 = \begin{pmatrix} 10 \\ 10 \end{pmatrix}$,

$$H_0 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

解: $\nabla f(x) = \begin{pmatrix} 3x_1 - x_2 \\ -x_1 + x_2 \end{pmatrix}$,

$$\nabla f(x^0) = \begin{pmatrix} 20 \\ 0 \end{pmatrix}, v^0 = -H_0 \nabla f(x^0) = -\begin{pmatrix} 20 \\ 0 \end{pmatrix}$$

从 x^0 出发沿着方向 v^0 作一维搜索。

$$\min_{\lambda} f(x^0 + \lambda v^0)$$

$$\varphi(\lambda) = f(x^0 + \lambda v^0) = 100 - 400\lambda + 600\lambda^2$$

$$\frac{d\varphi}{d\lambda} = -400 + 1200\lambda = 0, \lambda_0 = 0.33$$

$$x^1 = x^0 + \lambda_0 v^0 = (3.34, 10)^T$$

• 例 4_11

$$\nabla f(x^1) = \begin{pmatrix} 0.00 \\ 6.66 \end{pmatrix}, \quad u^0 = \lambda_0 v^0 = - \begin{pmatrix} 6.6 \\ 0 \end{pmatrix}$$

$$y^0 = \nabla f(x^1) - \nabla f(x^0) = - \begin{pmatrix} 20 \\ -6.66 \end{pmatrix}$$

$$A_i = \frac{u^i (u^i)^T}{(u^i)^T y^i}, \quad B_i = \frac{H_i y^i (H_i y^i)^T}{(y^i)^T H_i y^i}$$

$$A_0 = \begin{bmatrix} 0.33 & 0 \\ 0 & 0 \end{bmatrix}, \quad B_0 = - \begin{bmatrix} 0.9 & 0.3 \\ -0.3 & 0.01 \end{bmatrix}$$

$$H_{i+1} = H_i + A_i - B_i$$

$$H_1 = H_0 + A_0 - B_0 = \begin{bmatrix} 0.43 & 0.3 \\ 0.3 & 0.1 \end{bmatrix}$$

• 例 4_11

$$\square v^1 = -H_1 \nabla f(x^1) = -\begin{pmatrix} 2 \\ 6 \end{pmatrix}$$

从 x^1 出发沿着方向 v^1 作一维搜索。

$$\min_{\lambda} f(x^1 + \lambda v^1)$$

$$\lambda_1 = 5/3$$

$$x^2 = x^1 + \lambda_1 v^1 = (-0, 0)^T$$

$$H_2 = H_1 + A_1 + B_1 = \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 1.5 \end{bmatrix}$$

H_2 有何特点?

- 作业