

2019

# 最优化理论与方法

研究生学位课

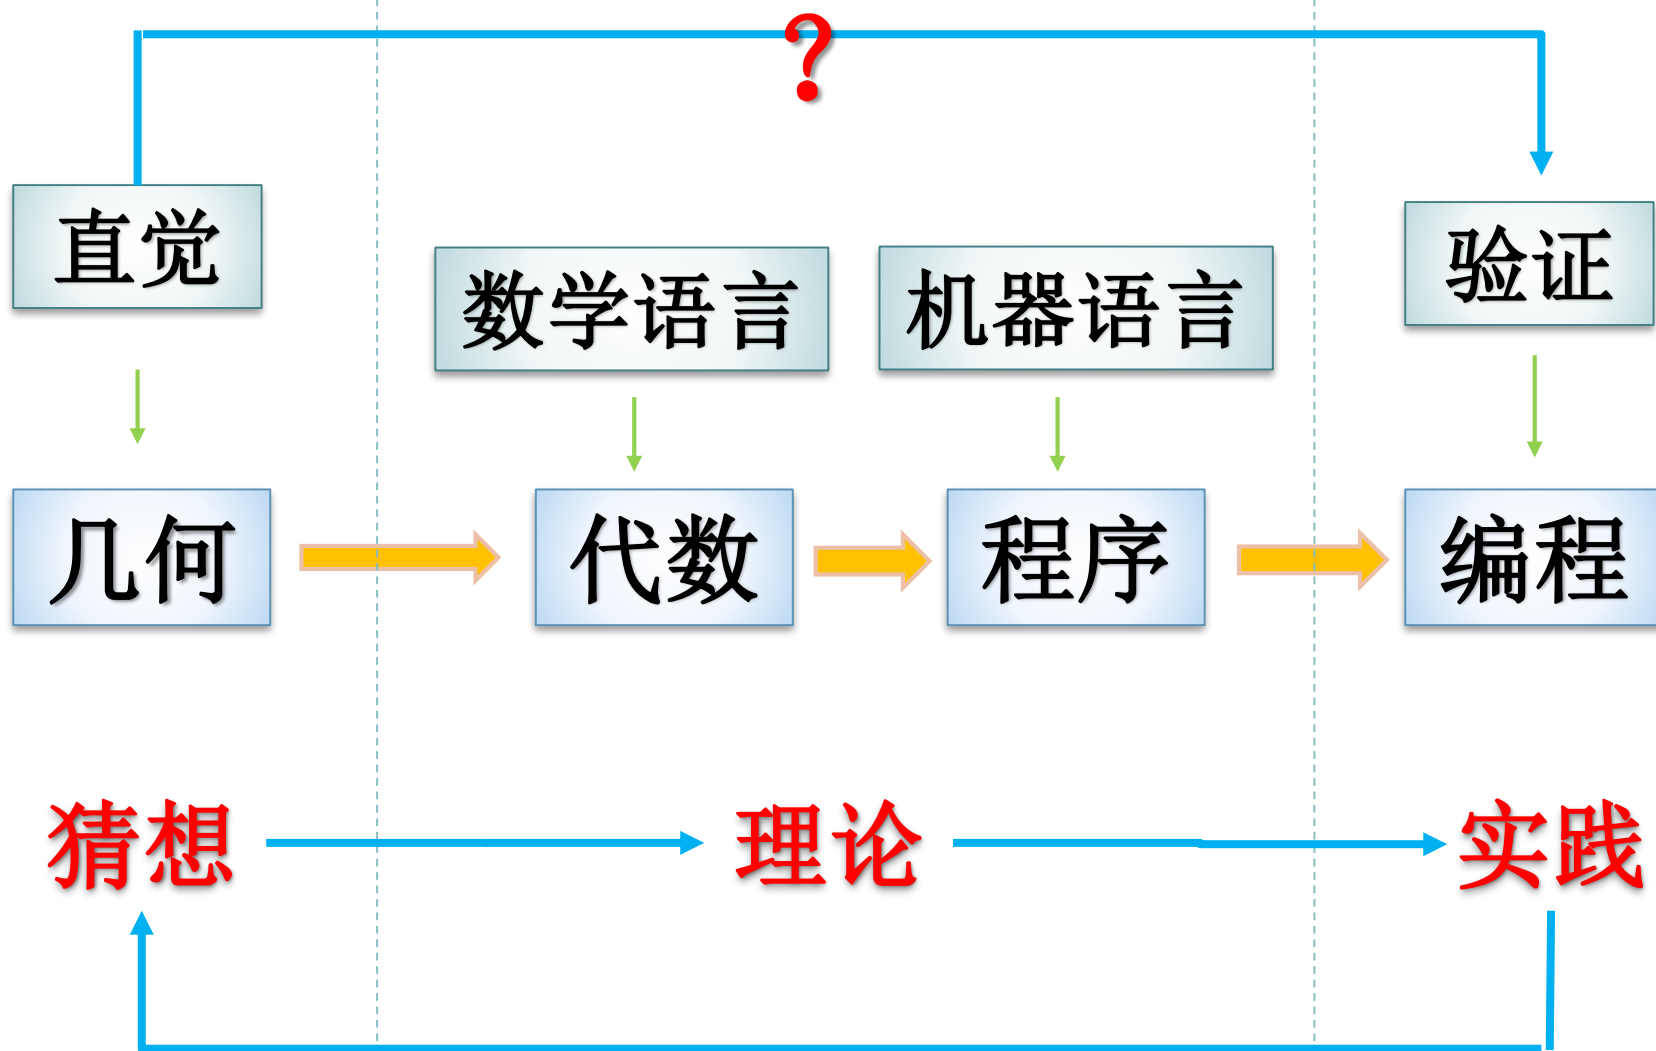
陈军华（副教授/主任）

- 课程学习的两个目标

- 最优化的概念、理念、思路、方法
- 在计算上编程实现

- 基础知识

- 线性规划
- 微积分
- 矩阵、线代
- **Matlab, Gams(cplex); Python, C#, C++.**



## • 参考书籍

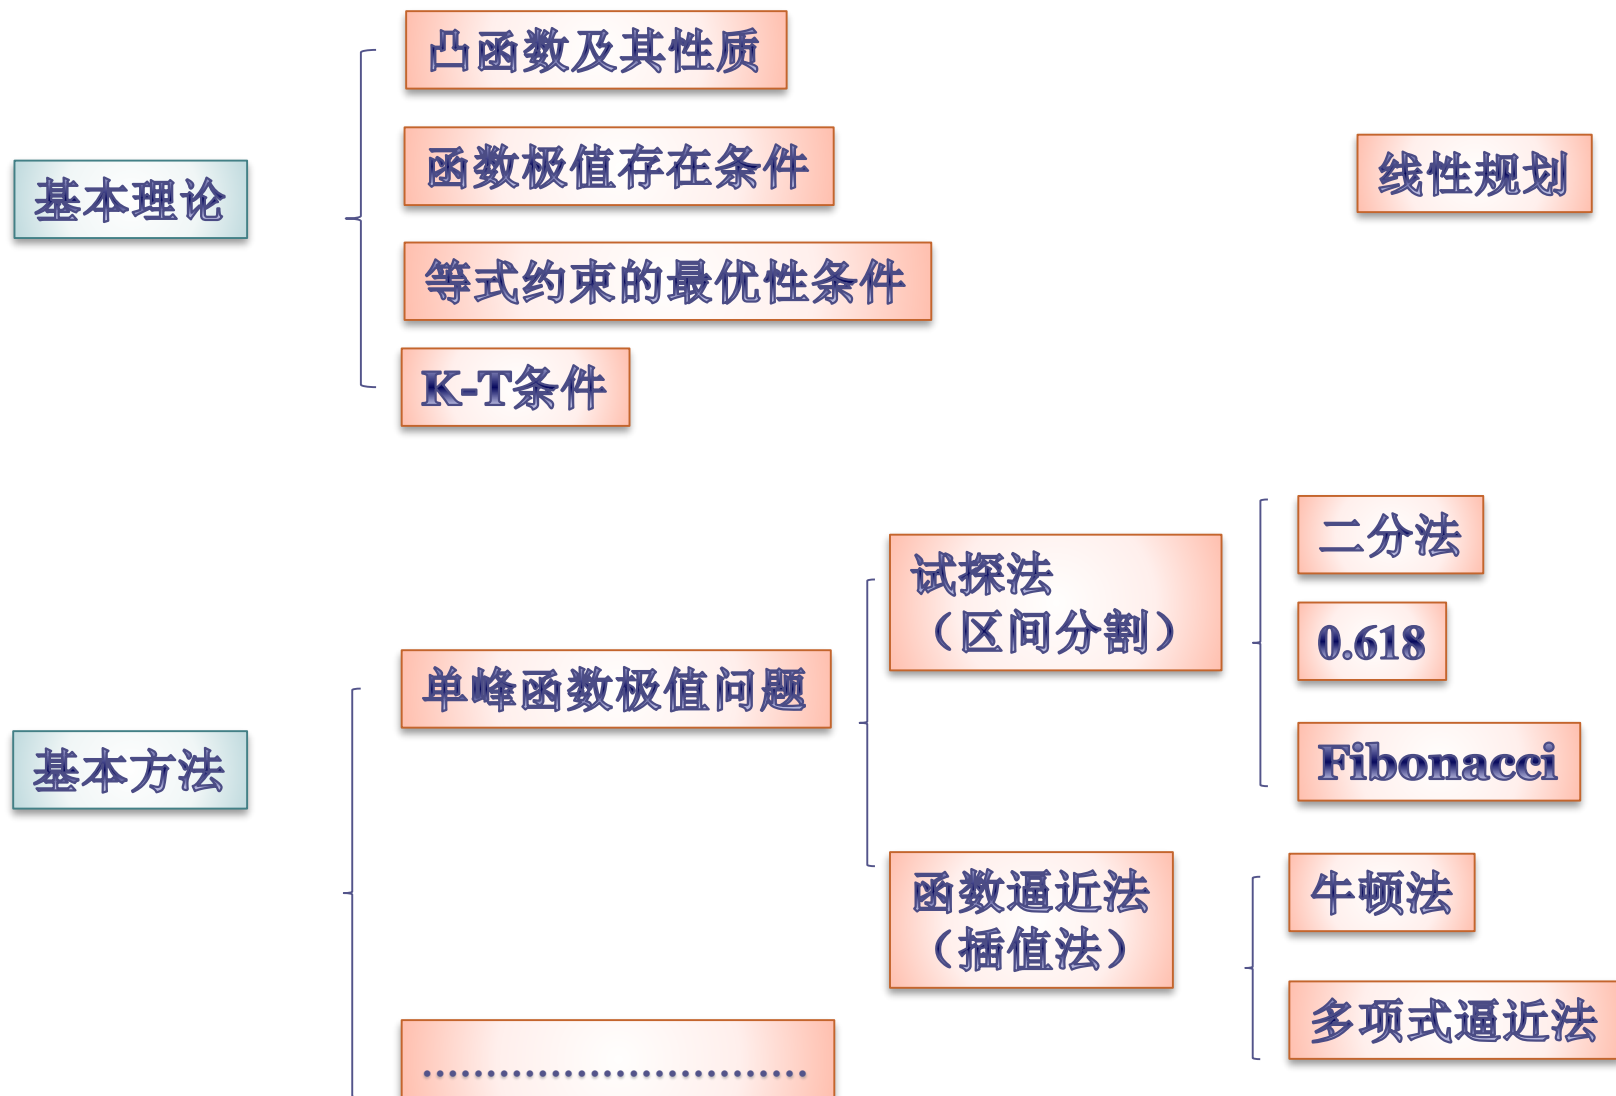
- ▣ **Linear and Nonlinear Programming, David G. Luenberger  
Stanford University, 2008**
- ▣ 陈宝林, 最优理论与方法, 清华大学出版社, 1989
- ▣ 袁亚湘, 孙文瑜, 最优化理论与方法, 科学出版社, 1997
- ▣ **Dimitri P. Bertsekas, Nonlinear Programming, second Edition,  
Athena Scientific, Belmont, MA, 1999**
- ▣ 陈军华, 铁路运输经典问题建模与实现, 2019
- ▣ 龚纯, 王正林, 精通MATLAB最优化计算, 第2版, 2012
- ▣ 宋叶志, 徐导, C#科学计算讲义, 2012

- 学习资料-云盘分享

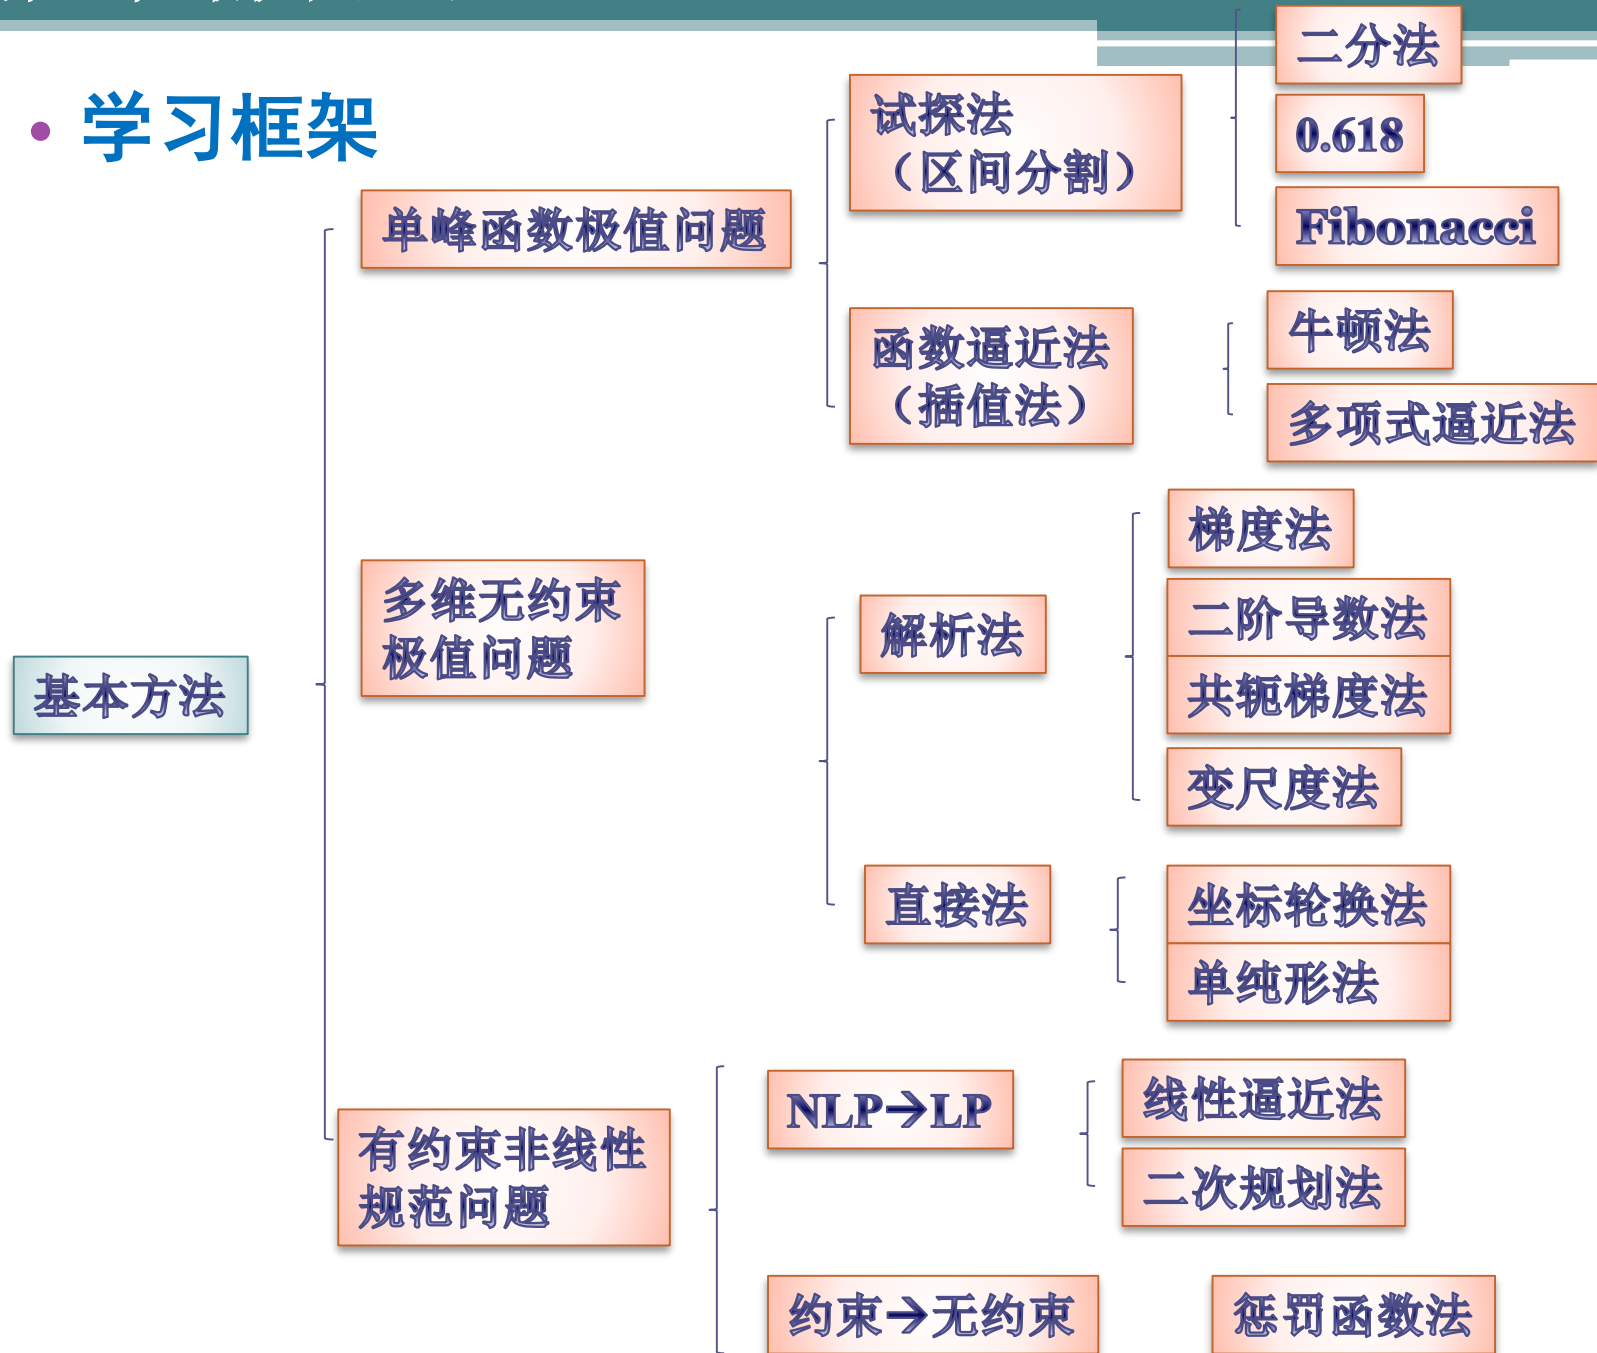
链接: [https://pan.baidu.com/s/1g4D42OD3WAaz8lkWbLH7\\_Q](https://pan.baidu.com/s/1g4D42OD3WAaz8lkWbLH7_Q)  
提取码: ml0o



## • 学习框架



## • 学习框架



### • Example 1

- 某公司经营两种物资，第一种每吨售价30元，第二种每吨售价是450元，据统计每售出1吨一、二种物资的平均营业时间为0.5h和  $(2+0.25x_2)$  h，其中 $x_2$ 是第二种物资的出售量。若该公司在这段时间里的总营业时间为800小时，试决定营业额最大的营业计划。



## • Example 1

▫ 解：设 $x_1$ ,  $x_2$ 分别为第一、二种物资的出售量。

其目标是：  $\max f(x) = 30x_1 + 450x_2$

约束条件：  $0.5x_1 + (2+0.25x_2)x_2 \leq 800$

$$x_1, x_2 \geq 0$$

Maximize  $30x_1 + 450x_2$

即：  $s.t.$   $0.5x_1 + 2x_2 + 0.25x_2^2 \leq 800$

$$x^1, x^2 \geq 0$$

象这种含有非线性函数的规划模型就是非线性模型。

### • Example 2

- 一投资者拥有资金5万元，准备向两个项目分别以 $x_1$ ， $x_2$ (万元)投资，两个项目的效益分别为20%，16%。所承担的风险损失数为： $2x_1^2 + x_2^2(x_1 + x_2)^2$ 元，投资者希望知道怎样的投资方案既可使收益最大，而所承担的风险最小。

## • Example 2

解：该问题要求收益最大，风险最小，这是一个多目标问题，为了求解，引进一个风险损失系数 $\theta \geq 0$ ，将多目标化为单目标问题：

$$\max p = 2000x_1 + 1600x_2 - \theta[2x_1^2 + x_2^2(x_1 + x_2)^2]$$

$$s.t. \quad x_1 + x_2 = 5$$

$$x_1, x_2 \geq 0$$

- **建立NLP的模型的步骤**

- **step1:设变量;**
- **step2:找目标, 建立目标函数;**
- **step3:寻找全部约束;**
- **step4:非负约束。**

## • NLP的通用模型

由上面的例子知NLP有各种形式，我们可以用通用模型表示：

$$\min f(x)$$

$$s.t. \quad g_i(x) \geq 0 \quad i = 1, \dots, m$$

$$h_i(x) = 0 \quad i = 1, \dots, p$$

$$x \in E^n$$

- 其中  $m \geq 0, p \geq 0, f(x), g_i(x), h_i(x)$  至少有一个是  $x$  的非线性函数。
- $f(x)$ : 代价函数（目标函数） **Cost function**
- $x$ : 决策变量
- $X$ : 约束集

## • NLP的通用模型

- 若令 $R$ 表示 $NLP$ 的可行解集合（即可行域），模型又可表示成集合的形式：

$$\min f(x)$$

$NLP$ :

$$\mathbf{R} = \{x \mid g_i(x) \geq 0, i = 1, \dots, m; h_j(x) = 0, j = 1, \dots, p; x \in E^n\}$$

- 求解非线性规划与求解线性规划一样，就是在可行域中求出目标函数最小值的点，只是对于复杂的规划不易求得其精确解，只能借助于迭代法求得近似最优解。

## • NLP的图解法

▫ 例:  $\min f(x) = 2(x_1 - 3.5)^2 + 4(x_2 - 4)^2 + 2$

$$s. t. \quad x_1 + x_2 - 6 \leq 0$$


$$6x_1 - x_2^2 + 16 \geq 0$$

$$(x_1 + 4)^2 + (x_2 - 9)^2 - 121 \leq 0$$

$$x_1, x_2 \geq 0$$

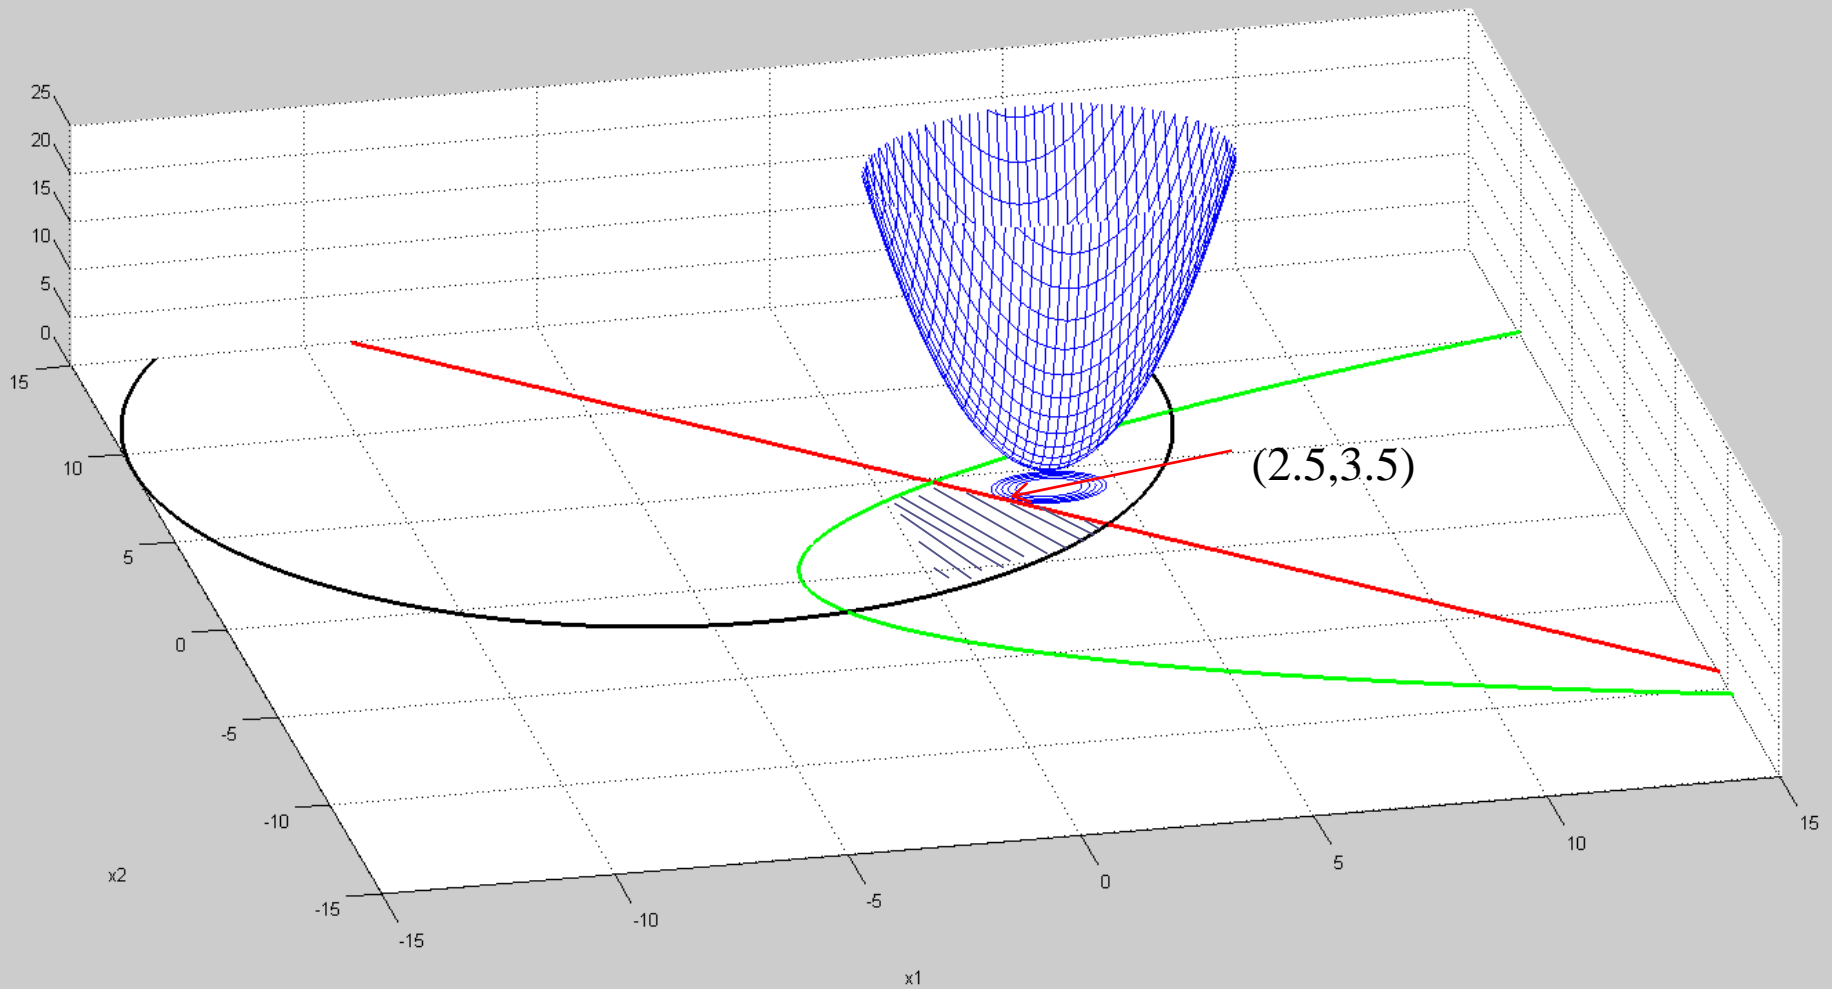
- 先在三维空间中划出可行域 $R$ ,然后画出目标函数的立体图。

- **NLP的图解法(ex1)**





## • NLP的图解法



## • NLP的最优解与局部最优解

### ▣ 1. 最优解

定义1: 若 $x^* \in R$ 是NLP的最优解点,当且仅当对于任意的 $x \in R$ 均有:


$$f(x) \geq f(x^*) \quad (4)$$

若上式为严格不等式,则 $x^*$ 为NLP的严格最优解点。

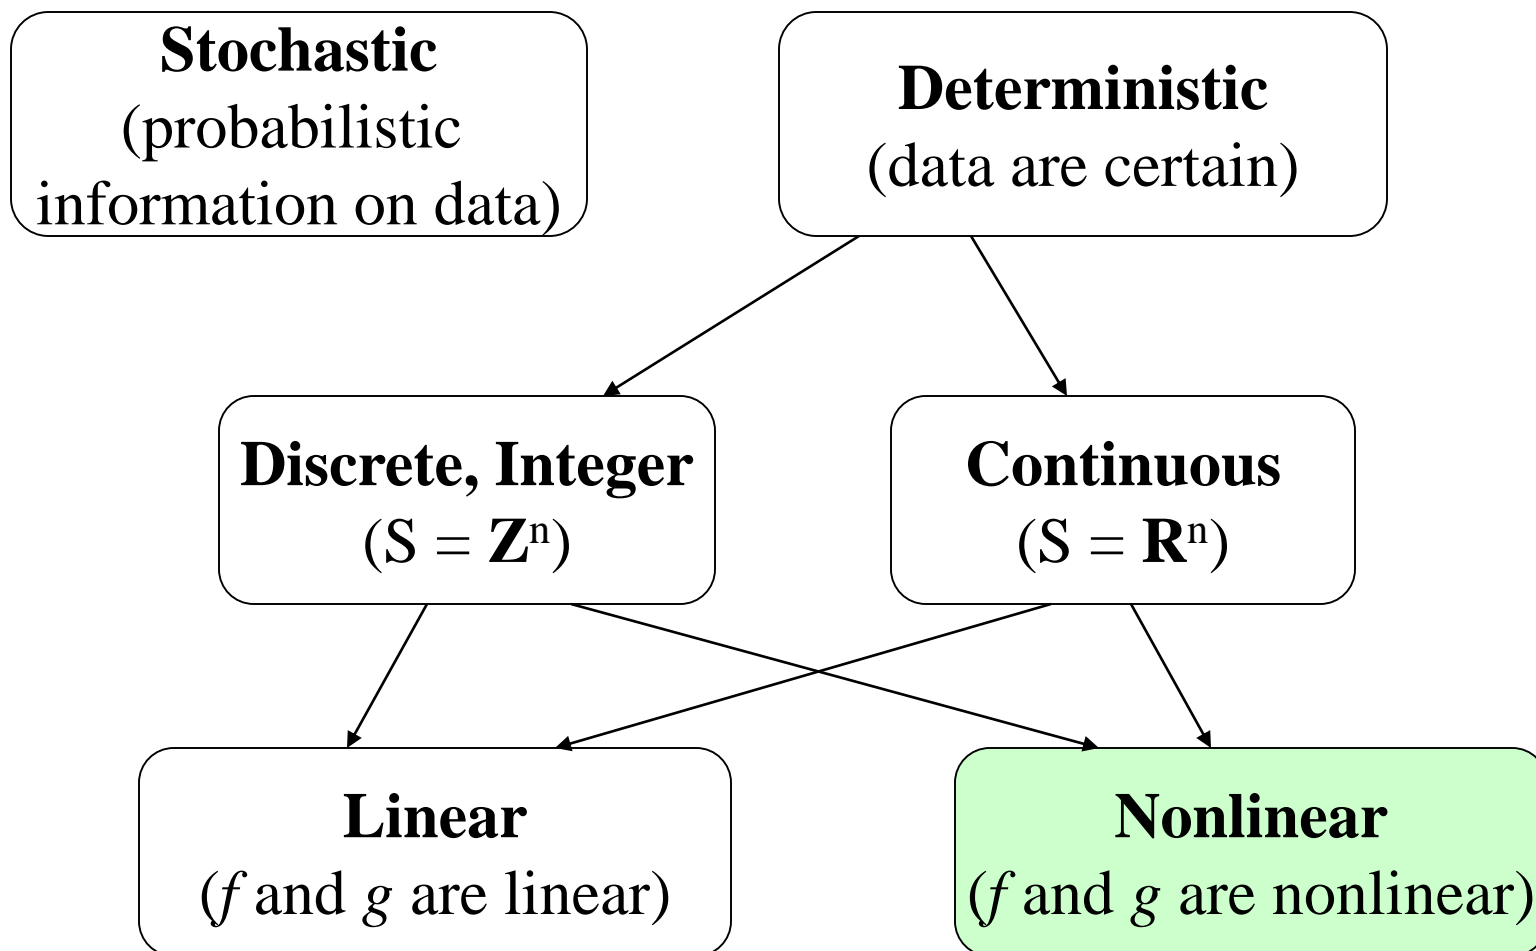
若NLP的最优节点不是唯一, 则记最优解集合为 $R^*$ 。

## • NLP的最优解与局部最优解 (ex2)

设: NLP  $\min_{x \in E^2} f(x)$   
 $st. g_1(x) \geq 0$   
 $g_2(x) \geq 0$



## • 最优化类型




## • 非线性规划的特点

- NLP的可行域**不一定是凸集**，甚至是由几个不连通的部分组成。
- NLP有局部最优解和全局最优解之分，这就要求我们寻优的时候不能停留在局部最优解点，要大区域搜索。
- NLP的最优解不一定在 $R$ 的极点上，也不一定在 $R$ 边界上，它的寻优范围比LP大。
- NLP的求解中，一般不易求得精确解，大都是近似最优解。


### • Example 1\_3

- An example with nonlinear constraints when the optimal solution is not a corner point feasible solution.



## • Example 1\_4

- ▣ An example with linear constraints but nonlinear objective function when the optimal solution is not a corner point feasible solution.



$$\begin{aligned} \text{Max } z &= 126x_1 - 9x_1^2 + 182x_2 - 13x_2^2 \\ \text{s.t. } x_1 &\leq 4 \\ &+ 2x_2 \leq 12 \\ 3x_1 &+ 2x_2 \leq 18 \\ x_1, x_2 &\geq 0 \end{aligned}$$


$$z = 907$$

$$z = 857$$

$$z = 807$$

## • Example 1\_5

- An example when the optimal solution is inside the boundary of the feasible region.




$$\begin{aligned}
 \text{Max } z &= 54x_1 - 9x_1^2 + 78x_2 - 13x_2^2 \\
 \text{s.t. } x_1 &\leq 4 \\
 &+ 2x_2 \leq 12 \\
 3x_1 + 2x_2 &\leq 18 \\
 x_1, x_2 &\geq 0
 \end{aligned}$$



## • Example 1\_6

- An example when a local maximum is not a global maximum (the feasible region is not a convex set).



$$\begin{array}{llllll}
 \text{Max } z = 3x_1 + 5x_2 & & & & & \\
 \text{s.t. } & x_1 & & & & \leq 4 \\
 & & & + & 2x_2 & \leq 14 \\
 8x_1 - x_1^2 + 14x_2 - x_2^2 & \leq 49 \\
 & x_1 & , & x_2 & \geq 0
 \end{array}$$

$$z = 27 = 3x_1 + 5x_2$$

# 基本理论与基础知识

## • NLP的最优解与局部最优解

### ▣ 1. 最优解

定义1: 若 $x^* \in R$ 是NLP的最优解点,当且仅当对于任意的 $x \in R$ 均有:

$$f(x) \geq f(x^*) \quad (4)$$

若上式为严格不等式,则 $x^*$ 为NLP的严格最优解点。

若NLP的最优点不唯一, 则记最优解集合为 $R^*$ 。

## • 邻域的概念

### ▣ 定义

$x$ 轴上某点 $x_0$ ，正数 $\varepsilon > 0$ ，则 $(x_0 - \varepsilon, x_0 + \varepsilon)$ 称为 $x_0$ 点的一个邻域。

### ▣ 定义-扩展到N维

设点 $x_0 \in E_n$ ，实数 $\varepsilon > 0$ ，则集合 $\{x | \|x - x_0\| < \varepsilon\}$ 称为 $x_0$ 点的一个以半径为 $\varepsilon$ 的邻域，记为 $N_\varepsilon(x^0)$

几何意义？

## • 局部最优解概念

### ▣ 定义


设 $n$ 维欧氏空间的一点 $x^* \in R$ 的某个邻域 $N_\varepsilon(x^*) = \{x | \|x - x_0\| < \varepsilon\}$ ,使得对所有的 $x \in R \cap N_\varepsilon(x^*)$ 都有:

$$f(x) \geq f(x^*)$$

则称 $x^*$ 为NLP的局部最优解点。

若上式换成严格不等式 $f(x) > f(x^*)$ 则称 $x^*$ 为NLP的严格局部最优点。局部最优点是否是全局最优点, 需要进行比较或鉴别才能知道。

## • 局部最优解与全局最优解



$f(x) \geq f(x^*) \forall x$  满足  $\|x - x^*\| < \varepsilon$ , 则  $x$  为局部最优

$f(x) \geq f(x^*) \forall x \in X$ , 则  $x$  为全局最优

以上 “ $\geq$ ” 换为 “ $>$ ” 则为严格最优

- 如果目标函数有多个局部最优解，如何取得全局最优？

- 1、大部分的最优化理论和算法求的是局部最优解。
- 2、如果目标函数为凸函数，局部最优即为全局最优。如果目标函数为严格凸函数，最优解也唯一。故凸函数与凹函数亦称为单峰函数。
- 3、使用随机优化算法，如：模拟退火、遗传算法理论上可以找到全局最优解。


## • 凸集

### ▣ 定义

$\forall x^1, x^2 \in R, x^1, x^2$  为两点连线的点, 那么:

$$\lambda x^1 + (1 - \lambda)x^2 \in R^n$$

称  $R$  为凸集



例:  $X = \{x | \|x\| \leq 5, x \in R^2\}$

$Y = \{y | 2 \leq \|y\| \leq 6, y \in R^2\}$




## • 超平面

### ▫ 定义

$X = \{x | c^T x = z\} x \neq 0, z$  为常数, 那么: 称 $X$ 为超平面

▫ 超平面将空间分成两部分:  $c^T x \geq z, c^T x \leq z$



## • 凸函数及其性质

- 定义

- 设  $R \subseteq E^n$  为凸集, 若对任意  $x^1 \in R, x^2 \in R, x^1 \neq x^2$  以及数  $\lambda, 0 \leq \lambda \leq 1$  有:


$$f\left(x^1 + \lambda(x^2 - x^1)\right) \leq f(x^1) + \lambda[f(x^2) - f(x^1)]$$

称  $f(x)$  在  $\mathbf{R}$  上为凸函数。上式可写成:

$$f(\lambda x^2 + (1 - \lambda)x^1) \leq \lambda f(x^2) + (1 - \lambda)f(x^1)$$


若换成严格不等式, 则  $f(x)$  为严格凸函数。

## • 凸函数及其性质



## • 凸函数及其性质

- 若将上式的不等式反转，则所定义的函数是凹函数和严格凹函数。



上面的（1）、（2）图为凹函数，（3）既不是凸函数也不是凹函数（分区域论）。线性函数在整个 $E^n$ 空间中，既为凸函数，又为凹函数，但既非严格凸函数又非严格凹。

## • 凸函数的性质

- 1. 设  $f(x)$  是凸集  $R$  上的一凸（凹）函数，则对于任意  $\lambda \geq 0$ ，函数  $\lambda f(x)$  在  $R$  上是凸（凹）的。由定义即可证得。
- 2. 设  $f_1(x), f_2(x)$  是凸集  $R$  上的凸（凹）函数，则  $f(x) = f_1(x) + f_2(x)$  在  $R$  上也是凸（凹）函数。

证明性质2.

## • 凸函数的性质2证明

□ 证明：设  $f(x) = f_1(x) + f_2(x)$

$\because f_1(x), f_2(x)$  是凸的。

$$\therefore f_1(x^1 + \lambda(x^2 - x^1)) \leq f_1(x^1) + \lambda[f_1(x^2) - f_1(x^1)] \quad (1)$$

$$f_2(x^1 + \lambda(x^2 - x^1)) \leq f_2(x^1) + \lambda[f_2(x^2) - f_2(x^1)] \quad (2)$$

(1)+(2) 得：

$$f(x^1 + \lambda(x^2 - x^1)) = f_1(x^1 + \lambda(x^2 - x^1)) + f_2(x^1 + \lambda(x^2 -$$

- **凸函数的性质**

通过反复运用上两性质可得：

有限个在凸集 $R$ 上的凸（凹）函数的**非负线性组合的函数**：

$$f(x) = \lambda_1 f_1(x) + \lambda_2 f_2(x) + \cdots + \lambda_m f_m(x)$$

仍然是凸（凹）函数，其中 $\lambda_i \geq 0$ ， $i = 1, 2, \dots, m$ 。

- **Example**

- 判别函数  $f(x) = \frac{1}{x} + 2x^3 + 3x^4 + (x - 5)^2 + 2e^x + chx$  在区间  $(0, +\infty)$  上是否是凸函数。  $chx = \left(\frac{e^x + e^{-x}}{2}\right)$



## • 凸函数的性质

### ▣ 性质3

- ▣ 设 $f(x)$ 是可微函数，则 $f(x)$ 在开凸集 $R$ 上为凸函数（或严格凸函数）的充分必要条件是：对任意 $x^1, x^2 \in R$ 有：

$$f(x^2) - f(x^1) \geq \nabla^T f(x^1)(x^2 - x^1) \text{ 或}$$
$$f(x^2) - f(x^1) > \nabla^T f(x^1)(x^2 - x^1) \quad x^1 \neq x^2$$

其中， $\nabla^T f(x^1)$ 表示函数在点 $x^1$ 上的梯度（一阶偏导数）

$$\nabla f(x) = \left( \frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T$$

## • 方向导数


- 设函数 $Z = f(x, y)$ 在 $p$ 点的某一领域内有定义，称 $f(x, y)$ 在点 $p$ 沿方向 $d$ 的变化率为 $f(x, y)$ 在点 $p$ 沿方向 $d$ 的方向导数。

$$\frac{\partial f}{\partial d} = \lim_{\rho \rightarrow 0} \frac{f(x + \Delta x, y + \Delta y) - f(x, y)}{\rho}$$

$\therefore f(x, y)$ 在 $p$ 点沿 $x$ 方向的方向导数是 $\frac{\partial f}{\partial x}$

$f(x, y)$ 在 $p$ 点沿 $y$ 方向的方向导数是 $\frac{\partial f}{\partial y}$

$$\therefore \frac{\partial f}{\partial d} = \frac{\partial f}{\partial x} \cos \alpha + \frac{\partial f}{\partial y} \sin \alpha$$



## • 梯度

- 梯度是与方向导数关联的一个概念，假设 $z = f(x, y)$ 在某一领域内具有一阶连续偏导数，则对于平面上的每一点 $p(x, y)$ 可定义一个向量：

$$\frac{\partial f}{\partial x}i + \frac{\partial f}{\partial y}j$$

- 就叫做  $f(x, y)$  在  $p$  点的梯度。方向导数表示  $f(x, y)$  在点沿  $d$  方向的变化率，而梯度则表示函数  $f(x, y) = c$  (等值线) 在  $p$  点的法线方向。
- $NLP$  中研究的都是  $n$  维的情形。

## • 充要性证明

### ▣ 证明：必要性

设 $f(x)$ 是凸函数，任选 $\lambda(0 \leq \lambda \leq 1)$ 有

$$f\left(x^1 + \lambda(x^2 - x^1)\right) \leq \lambda f(x^2) + (1 - \lambda)f(x^1) \cdots (1)$$

整理：  $f\left(x^1 + \lambda(x^2 - x^1)\right) - f(x^1) \leq \lambda[f(x^2) - f(x^1)]$

即：  $\frac{f\left(x^1 + \lambda(x^2 - x^1)\right) - f(x^1)}{\lambda} \leq f(x^2) - f(x^1) \cdots (2)$

取极限：  $\lim_{\lambda \rightarrow 0} \frac{f\left(x^1 + \lambda(x^2 - x^1)\right) - f(x^1)}{\lambda(x^2 - x^1)} (x^2 - x^1) \leq f(x^2) - f(x^1)$

$$\nabla^T f(x^1)(x^2 - x^1) \leq f(x^2) - f(x^1)$$

必要性得证.

## • 充要性证明

- 若设 $f(x)$ 在 $Z$ 上为严格凸函数，(2)式换成严格不等式后不能两边取极限. 现假设中间变量： $z = \frac{1}{2}x^1 + \frac{1}{2}x^2, z \in R$ .

由于严格凸也是凸函数，则由(1)式得：

$$f(z) < \frac{1}{2}f(x^1) + \frac{1}{2}f(x^2)$$

考虑 $Z$ ， $x^1$ 两点，对凸函数 $f(x)$ 有： $\nabla^T f(x^1)(z - x^1) \leq f(z) - f(x^1)$

$$f(z) \geq f(x^1) + \nabla^T f(x^1)(z - x^1)$$

$$\therefore \frac{1}{2}f(x^1) + \frac{1}{2}f(x^2) > f(z) \geq f(x^1) + \nabla^T f(x^1)(z - x^1)$$

$$= f(x^1) + \frac{1}{2}\nabla^T f(x^1)(x^2 - x^1)$$

$$\therefore f(x^2) > f(x^1) + \nabla^T f(x^1)(x^2 - x^1)$$

### • 性质3充分性证明

设  $x^1, x^2 \in R, 0 \leq \lambda \leq 1$ , 令  $z = \lambda x^2 + (1 - \lambda)x^1$ , 则  $z \in R$

$$\because f(x^2) \geq f(x^1) + \nabla^T f(x^1)(x^2 - x^1)$$

则有:  $f(x^2) \geq f(z) + \nabla^T f(z)(x^2 - z)$

$$f(x^1) \geq f(z) + \nabla^T f(z)(x^1 - z)$$

将上两式分别乘以  $\lambda, (1 - \lambda)$  相加得:

$$\lambda f(x^2) + (1 - \lambda)f(x^1)$$

$$\geq \lambda f(z) + (1 - \lambda)f(z) + \nabla^T f(z) [\lambda(x^2 - z) + ((1 - \lambda)(x^1 - z))]$$

$$= f(z) + \nabla^T f(z) [\lambda x^2 - \lambda z + (1 - \lambda)x^1 - z + \lambda z]$$


$$= f(z) = f[\lambda x^2 + (1 - \lambda)x^1]$$

$$\text{即: } f[\lambda x^2 + (1 - \lambda)x^1] \leq \lambda f(x^2) + (1 - \lambda)f(x^1)$$

故  $f(x)$  为凸函数, 严格凸函数情况类此。证毕。

## • 几何意义

- $x^2$  与  $x^1$  点的函数值差总大于等于从  $x^1$  点做切线的纵坐标值。



## • 凸函数的性质

### ▫ 性质4

- 设 $f(x)$ 是二阶可微的，则 $f(x)$ 在开凸集 $R$ 上为凸函数的充分必要条件是：对一切 $x \in R$ ，Hesse矩阵 $H(x)$ 为半正定的。若 $H(x)$ 为正定的，则 $f(x)$ 为严格凸函数。

### ▫ 性质4充要性证明



- 凸函数的性质

- **Hesse矩阵**:  $f(x)$ 的Hesse矩阵是函数 $f(x)$ 对各 $x$ 分量求二阶偏导组成的矩阵。

$$\nabla^2 f(x) = H(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \vdots & \vdots & \cdots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_n \partial x_n} \end{bmatrix}$$

## • 凸函数的性质

- 其二是矩阵的正定与半正定，由线性代数学可知，矩阵 $\mathbf{H}$ 正定的充要条件是 $\mathbf{ZHZ}$ 二次型正的，半正定是 $\mathbf{ZHZ} \leq 0$ ，负定是 $\mathbf{ZHZ} < 0$ ；二次型 $\mathbf{ZHZ}$ 为正定的充要条件是它的各阶主子式都大于零，半正定是各阶主子式均大于等于零，负定是各阶主子式正负相间。

- 即：正定 
$$h_{11} > 0, \begin{bmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{bmatrix} > 0, \dots, \begin{bmatrix} h_{11} & \dots & h_{1n} \\ \vdots & & \vdots \\ h_{n1} & \dots & h_{nn} \end{bmatrix} > 0$$

- 半正定：将上面的 $>$ 号改 $\geq$ 号

- 负定： 
$$h_{11} < 0, \begin{bmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{bmatrix} > 0, \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} < 0, \dots, (-1)^n \begin{bmatrix} h_{11} & \dots & h_{1n} \\ \vdots & & \vdots \\ h_{n1} & \dots & h_{nn} \end{bmatrix} > 0$$

## • 泰勒定理

- 若函数 $f(x)$ 在点 $x_0$ 的某一领域内具有直到 $(n + 1)$ 阶的导数, 则有:

$$\begin{aligned} f(x) \\ = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2}(x - x_0)^2 + \cdots + \frac{f^n(x_0)}{n!}(x - x_0)^n + R_n(x) \end{aligned}$$

$R_n(x)$ : 拉格郎日余项, 高阶无穷小

## • 性质4必要性证明

- 设 $f(x)$ 为 $R$ 上的凸函数, 任取 $x \in R, z \in E^n$
- $\because R$ 为凸开集, 故存在领域 $\sigma$ , 当 $\lambda \in [-\sigma, +\sigma]$ 时

$$x + \lambda z \in R$$

由性质3可知: 
$$f(x + \lambda z) \geq f(x) + \nabla^T f(x)(x + \lambda z - x)$$
$$= f(x) + \lambda \nabla^T f(x)z$$

$$\therefore f(x + \lambda z) - f(x) \geq \lambda \nabla^T f(x)z$$

- 又 $\because f(x)$ 在 $x$ 处是二阶可微的, 由Taylor 定理将 $f(x + \lambda z)$ 在 $x$ 点处展开:

$$f(x + \lambda z) = f(x) + \lambda \nabla^T f(x)z + \frac{\lambda^2}{2} z^T H z + o(\lambda^2)$$

$$f(x + \lambda z) - f(x) - \lambda \nabla^T f(x)z = \frac{\lambda^2}{2} z^T H z + o(\lambda^2)$$

- 性质4证明

由 (2) 式可知:  $\frac{\lambda^2}{2} \mathbf{z}^T \mathbf{H} \mathbf{z} + o(\lambda^2) \geq 0$

$$\therefore \mathbf{z}^T \mathbf{H} \mathbf{z} \geq 0$$

故矩阵  $\mathbf{H}(\mathbf{x})$  半正定

## • 性质4证明

▫ 充分性

▫ 设 $H(x)$ 在 $R$ 上为半正定, 任取 $x^1, x^2 \in R, x^1 \neq x^2$

则有  $\alpha \in (0,1), x = \alpha x^1 + (1 - \alpha)x^2$

由Taylor式知:

$$f(x) = f(x^1) + \nabla^T f(x^1)(x - x^1) + \frac{1}{2}(x - x^1)^T H(x^1)(x - x^1) + o(\alpha)$$

$\because H(x^1)$ 是半正定的, 则有:

$$\frac{1}{2}(x - x^1)^T H(x^1)(x - x^1) \geq 0$$

$$\therefore f(x) \geq f(x^1) + \nabla^T f(x^1)(x - x^1)$$

由性质3知  $f(x)$ 在 $R$ 上为凸函数。

- 例

判断函数  $f(x_1, x_2) = 2x_1^2 + x_2^2 - 2x_1x_2 + x_1 + 1, x \in R^2$  的凸性。

## • 3 凸规划

设NLP为:  $(p) \min_{x \in R} f(x)$

$$R = \{x | g_i(x) \geq 0, i = 1, \dots, m\}$$

其中:  $f(x), g_i(x), i = 1, \dots, m$  为凸函数, 则  $p$  为凸规划。

▣ **定理: 若某问题为凸规划, 则:**

- 1)  $p$  的可行解集合  $R$  为凸/凹集;
- 2)  $p$  的最优解集合  $R^*$  为凸/凹集;
- 3)  $p$  的任何局部最优解都是全局最优解;
- 4) 若  $f(x)$  为严格凸函数, 且  $p$  的最优解集合  $R^* \neq \varnothing$ , 则最优解必唯一。



## • 证明定理1

▣ 证:  $p$  的可行解集合  $R$  为凸集.

不妨设  $R \neq \varnothing$ , 因为空集也是凸集,

则对于任意的两点:  $x^1, x^2 \in R$ , 及  $\lambda \in (0, 1)$  有:

$$g_i(x^1) \geq 0, g_i(x^2) \geq 0$$

$\because g_i(x)$  是凹函数

$$\therefore g_i(\lambda x^1 + (1 - \lambda)x^2) \geq \lambda g_i(x^1) + (1 - \lambda)g_i(x^2) \geq 0$$

$$\therefore g_i(\lambda x^1 + (1 - \lambda)x^2) \geq 0 \quad \forall i = 1, 2, \dots, m$$

即:  $\lambda x^1 + (1 - \lambda)x^2 \in R$        $R$  为凸集

## • 证明定理2

□ 证： $p$ 的最优解集合 $R^*$ 为凸集

$R^* \neq \emptyset$ , 取 $\bar{x}, \bar{y} \in R^*$

由(1)知, 对于任意的 $\lambda \in (0,1)$ 有:  $\lambda\bar{x} + (1-\lambda)\bar{y} \in R$

又 $\because f(\bar{x}), f(\bar{y})$ 为最优值, 则:  $f(\bar{x}) = f(\bar{y}) = \min_{x \in R} f(x)$

$\therefore f(\lambda\bar{x} + (1-\lambda)\bar{y}) \leq \lambda f(\bar{x}) + (1-\lambda)f(\bar{y}) = \min_{x \in R} f(x)$

上式只能取等号, 否则与假设矛盾, 即:

$$f(\lambda\bar{x} + (1-\lambda)\bar{y}) = \min_{x \in R} f(x)$$

$$\lambda\bar{x} + (1-\lambda)\bar{y} \in R^*$$

## • 证明定理3

- 证  $P$  的任何局部最优解为全局最优解。
- 反证法：设  $\bar{x}$  为  $P$  的局部最优解，那么存在  $\bar{x}$  的某领域  $N_\varepsilon(\bar{x})$

对于任意  $x \in N_\varepsilon(\bar{x}) \cap R$ , 都有  $f(x) \geq f(\bar{x})$

假设  $\bar{x}$  不是  $P$  的全局最优解，则必存在  $\bar{y} \in R$  有  $f(\bar{y}) < f(\bar{x})$

$\because f(x)$  是凸函数，故对  $\lambda \in (0,1)$  有：

$$\begin{aligned} f(\lambda\bar{x} + (1-\lambda)\bar{y}) &\leq \lambda f(\bar{x}) + (1-\lambda)f(\bar{y}) \\ &< \lambda f(\bar{x}) + (1-\lambda)f(\bar{x}) = f(\bar{x}) \end{aligned}$$

即：  $f(\lambda\bar{x} + (1-\lambda)\bar{y}) < f(\bar{x}) \dots\dots\dots (1)$

但，当  $\lambda$  足够接近 1 时，  $\lambda\bar{x} + (1-\lambda)\bar{y} \in N_\varepsilon(\bar{x}) \cap R$

又由局部最优解的定义知：

$$f(\lambda\bar{x} + (1-\lambda)\bar{y}) \geq f(\bar{x}) \dots\dots\dots (2)$$

故与 (1) 式矛盾，所以  $\bar{x}$  是  $P$  的全局最优解。

## • 证明定理4

▣ 证 (4)若 $f(x)$ 为严格凸函数, 且 $R^* \neq \varphi$ , 则最优解唯一。

▣ 反证法: 若最优解不唯一, 即存在 $\bar{x} \in R^*, \bar{y} \in R^*, \bar{x} \neq \bar{y}$ ,

取 $\lambda \in (0,1)$ 有:  $\lambda\bar{x} + (1 - \lambda)\bar{y} \in R^*$

$$\therefore f(\lambda\bar{x} + (1 - \lambda)\bar{y}) = f(\bar{x}) = f(\bar{y}) = \min f(x) \cdots \cdots (3)$$

又  $\because f(x)$ 严格凸,

$$\therefore f(\lambda\bar{x} + (1 - \lambda)\bar{y}) < \lambda f(\bar{x}) + (1 - \lambda)f(\bar{y}) = f(\bar{x})$$

此与  $\lambda\bar{x} + (1 - \lambda)\bar{y} \in R^*$  相矛盾, 或与 (3) 式相矛盾,

故得证。

### • 定理5

- 证 (5) 设  $P$  为凸规划,  $f(x)$  可微, 则  $x^*$  是  $P$  的最优解的充分必要条件是 对任意  $x \in R$  有:  $\nabla^T f(x^*)(x - x^*) \geq 0$
- 证明

## • 定理5

□ 证 (5) 设  $P$  为凸规划,  $f(x)$  可微, 则  $x^*$  是  $P$  的最优解的充分必要条件是 对任意  $x \in R$  有:  $\nabla^T f(x^*)(x - x^*) \geq 0$

□ 证明: 充分性

由凸函数性质3知, 对于任意  $x \in R$  有:

$$f(x) \geq f(x^*) + \nabla^T f(x^*)(x - x^*)$$

$$\therefore \nabla^T f(x^*)(x - x^*) \geq 0$$

$$\therefore f(x) \geq f(x^*) \quad \text{故 } x^* \text{ 为 } P \text{ 的最优解。}$$

## • 定理5

▫ 证 (5) 设  $P$  为凸规划,  $f(x)$  可微, 则  $x^*$  是  $P$  的最优解的充分必要条件是 对任意  $x \in R$  有:  $\nabla^T f(x^*)(x - x^*) \geq 0$

▫ 证明: 必要性

▫ 用反证法

若  $x^*$  是  $P$  的最优解, 但存在  $x^0 \in R$ , 使:  $\nabla^T f(x^*)(x^0 - x^*) < 0$

则由:  $f(x^* + \lambda(x^0 - x^*)) = f(x^*) + \lambda \nabla^T f(x^*)(x^0 - x^*) + o(\lambda)$

当取充分小的  $\lambda$  时, 总可以使  $\lambda \nabla^T f(x^*)(x^0 - x^*) + o(\lambda) < 0$

故有:  $f(x^* + \lambda(x^0 - x^*)) \leq f(x^*)$

与假设  $x^*$  是最优解矛盾, 故得证。