

凸集、凸函数与凸规划

凸集：S 中任意两点连线仍属于 S

凸函数：曲线上任意两点的弦不在曲线下方

凸函数性质：设 f(x) 是二阶可微的， f(x)在

开凸集 R 上为凸函数的充分必要条件是对一切 x∈ R, Hesse 矩阵 H(x)为半正定的。若 H(x)为正定的，则 f(x)为严格凸函数。

凸规划：求凸函数在凸集上的极小值

凸规划性质：局部最小就是全局最小

两点估计太高，一点估计太低：用凸函数两点之间的连线上的一点 R 来估计函数值 L, 永远有 R>L, （图 1）。用凸函数的切线上的一点 R 来估计函数值 L, 永远有 R<L, （图 2）。

斐波那契

给定初始区间[a₁, b₁]和最终区间长度 L, 求计算函数值的次数 n, 使

$$F_n \geq (b_1 - a_1) / L,$$

置辨别常数 δ>0. 计算试探点 λ₁ 和 μ₁,

$$\lambda_1 = a_1 + \frac{F_{n-1}}{F_n}(b_1 - a_1), \quad \mu_1 = a_1 + \frac{F_{n-1}}{F_n}(b_1 - a_1).$$

计算函数值 f(λ₁) 和 f(μ₁). 置 k=1.

(2) 若 f(λ_k)>f(μ_k), 则转步骤(3); 若 f(λ_k)≤f(μ_k), 则转步骤(4)

(3) 令 a_{k+1}=λ_k, b_{k+1}=b_k, λ_{k+1}=μ_k, 计算试探点 μ_{k+1},

$$\mu_{k+1} = a_{k+1} + \frac{F_{n-k-1}}{F_{n-k}}(b_{k+1} - a_{k+1}).$$

若 k=n-2, 则转步骤(6); 否则, 计算函数值 f(μ_{k+1}), 转步骤(5).

(4) 令 a_{k+1}=a_k, b_{k+1}=b_k, λ_{k+1}=μ_k, μ_{k+1}=λ_k 计算 λ_{k+1},

$$\lambda_{k+1} = a_{k+1} + \frac{F_{n-k-1}}{F_{n-k}}(b_{k+1} - a_{k+1}).$$

若 k=n-2, 则转步骤(6); 否则, 计算 f(λ_{k+1}), 转步骤(5).

(5) 置 k:=k+1, 转步骤(2).

置辨别常数 δ>0. 计算试探点 λ₁ 和 μ₁,

$$\lambda_1 = a_1 + \frac{F_{n-1}}{F_n}(b_1 - a_1), \quad \mu_1 = a_1 + \frac{F_{n-1}}{F_n}(b_1 - a_1).$$

计算函数值 f(λ₁) 和 f(μ₁). 置 k=1.

(2) 若 f(λ_k)>f(μ_k), 则转步骤(3); 若 f(λ_k)≤f(μ_k), 则转步骤(4).

(3) 令 a_{k+1}=λ_k, b_{k+1}=b_k, λ_{k+1}=μ_k, μ_{k+1}=λ_k 计算 λ_{k+1},

$$\mu_{k+1} = a_{k+1} + \frac{F_{n-k-1}}{F_{n-k}}(b_{k+1} - a_{k+1}).$$

若 k=n-2, 则转步骤(6); 否则, 计算函数值 f(μ_{k+1}), 转步骤(5).

(4) 令 a_{k+1}=a_k, b_{k+1}=b_k, λ_{k+1}=μ_k, μ_{k+1}=λ_k 计算 λ_{k+1},

$$\lambda_{k+1} = a_{k+1} + \frac{F_{n-k-1}}{F_{n-k}}(b_{k+1} - a_{k+1}).$$

若 k=n-2, 则转步骤(6); 否则, 计算 f(λ_{k+1}), 转步骤(5).

(5) 置 k:=k+1, 转步骤(2).

(6) 令 λ_k=λ_{n-1}, μ_k=λ_{n-1}+δ, 计算 f(λ_k) 和 f(μ_k).

若 f(λ_k)>f(μ_k), 则令

$$a_n = \lambda_n, \quad b_n = b_{n-1}.$$

若 f(λ_k)≤f(μ_k), 则令

$$a_n = a_{n-1}, \quad b_n = \lambda_n.$$

停止计算, 极小点含于[a_n, b_n].

黄金分割法和斐波那契法：斐波那契法在求解过程中利用斐波那契数列来简化运算.使得是下一步计算与上一步迭代相关，减少了计算量，另外，该算法在迭代次数较少的时候收敛速度大于黄金分割法，因此是效率和精度的最优平衡。由于黄金分割法和斐波那契法的渐进收敛率趋于一致，所以可以认为黄金分割法是斐波那契法的特例。

求 $f(t) = t^2 - t + 2$ 的近似极小点，区间为[-1,3]，

精度δ= 0.5

解

$f(t)$ 为下单峰函数，用微分法可知 $t^*=0.5$, $f(t^*)=1.75$

$L_n = \frac{L_1 + F_n - 2\varepsilon}{F_n} \quad \varepsilon = 0 \neq L_n = \frac{L_1}{F_n}$

$L_n = \frac{L_1}{F_n} \leq 0.5 \quad \rightarrow \quad F_n \geq \frac{3-(-1)}{0.5}=8 \quad \rightarrow \quad n=5$

计算 $L_2 = \frac{F_{n-1}L_1 - F_{n-2}L_2}{F_n} = \frac{5}{8} \times (4)=2.5$

计算 a_1, b_1

$x_1^*=b_0 - L_2 = 3 - 2.5=0.5$

$x_2^*=a_0 + L_2 = -1 + 2.5=1.5$

$f(x_1^*)=1.75 \quad f(x_2^*)=2.75 \rightarrow \quad f(x_2^*)>f(x_1^*)$

更新区间 $a_1=a_0 = -1, b_1=x_2^*=1.5$

更新点 $x_2^*=x_1^*=0.5, x_1^*=a_1+b_1-x_2^*=0$

黄金分割法

求 $f(t) = t^2 - t + 2$ 的近似极小点，区间为[-1,3]，

精度δ= 0.5. 使用 0.618 法。

计算 a_1, b_1 .

$x_1^*=a_0 + 0.382 \times (b_0 - a_0)=0.528$

$x_2^*=a_0 + 0.618 \times (b_0 - a_0)=1.472$

$f(x_1^*)=1.7508, \quad f(x_2^*)=2.6948 \rightarrow \quad f(x_2^*)>f(x_1^*)$

更新区间 $a_1=a_0 = -1, b_1=x_2^*=1.472$

更新点 $x_1^*=a_1+0.382 \times (b_1 - a_1)= -0.0557$

$x_2^*=x_1^*=0.528$

由于 $\frac{b_3-a_3}{2} = 0.4720 < \delta = 0.5$ 算法终止

$x^* = \frac{x_1^+ + x_2^+}{2}=0.4164 \quad f(x^*)=1.7570$

拉格朗日函数

• 作业(6.5)

求极大和极小

$f(x) = 2x^2 - 3y^2 - 2x$

$s.t. \quad x^2 + y^2 \leq 1$

令: $\theta^2 = 1 - x^2 - y^2$

$L = 2x^2 - 3y^2 - 2x + \lambda(\theta^2 - 1 + x^2 + y^2)$

$\frac{\partial L}{\partial x} = 4x - 2 + 2\lambda x = 0$

$\frac{\partial L}{\partial y} = -6y + 2\lambda y = 0$

$\frac{\partial L}{\partial \lambda} = \theta^2 - 1 + x^2 + y^2 = 0$

$\frac{\partial L}{\partial \theta} = 2\lambda \theta = 0$

• 1) $\theta = 0$

$4x - 2 + 2\lambda x = 0$

$-6y + 2\lambda y = 0$

$-1 + x^2 + y^2 = 0$

解得:

$\begin{pmatrix} 0.2 \\ \pm\sqrt{0.96} \\ 3 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ -3 \end{pmatrix}$

-3.2, 0, 4

• 2) $\lambda = 0$

$4x - 2 = 0$

$-6y = 0$

$-1 + x^2 + y^2 = \theta^2$

解得:

$\begin{pmatrix} 0.5 \\ 0 \\ \pm\sqrt{1.25} \end{pmatrix}$

• 3) $\lambda = 0, \theta = 0$

$4x - 2 = 0$

$-6y = 0$

$-1 + x^2 + y^2 = 0$

无解。

故: 极大值为4, 极小值为-3.2

最速下降法-梯度法

- 取初始点 $x^0 \in E^n$ ，允许误差 $\varepsilon > 0$.
- 计算负梯度方向 $d^p = -\nabla f(x^p)$, $\bar{d}^p = -\frac{\nabla f(x^p)}{\|\nabla f(x^p)\|}$ (可)
- 进行一维搜索 $\min_k f(x^p + kd^p)$
- 迭代: $x^{p+1} = x^p + kd^p$
- 精度判断为 $\|d^p\| \leq \varepsilon$

• 例 4.3

求 $f(x) = 4x_1 + 6x_2 - 2x_1^2 - 2x_1x_2 - 2x_2^2$ 的极值, $x^0 = (1,1)^T, \varepsilon = 0.5$

$\nabla f(x) = \begin{pmatrix} 4 - 4x_1 - 2x_2 \\ 6 - 2x_1 - 4x_2 \end{pmatrix}$

$\nabla^2 f(x) = \begin{pmatrix} -4 & -2 \\ -2 & -4 \end{pmatrix}$

• $AC - B^2 > 0$, 且 $A < 0, C < 0$ 具有极大值。

解: 令 $f(x) = -f(x) = -4x_1 - 6x_2 + 2x_1^2 + 2x_1x_2 + 2x_2^2$

$\nabla f(x) = \begin{pmatrix} -4 + 4x_1 + 2x_2 \\ -6 + 2x_1 + 4x_2 \end{pmatrix}, \quad \|\nabla f(x_0)\| = 2 > \varepsilon$

• 1) 第一次迭代

$d^0 = -\nabla f(x_0) = \begin{pmatrix} -2 \\ 0 \end{pmatrix}$

$x^1 = x^0 + k^0 d^0 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} + k^0 \begin{pmatrix} -2 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 - 2k^0 \\ 1 \end{pmatrix}$

• $g(k) = f(x^1) = -4(1 - 2k^0) - 6 \times 1 + 2 \times (1 - 2k^0)^2 - 2 \times (1 - 2k^0) \times 1 + 2$

$\frac{dg(k)}{dk} = -16k^0 + 4$

$\bar{k}^0 = 1/4$

$x^1 = \begin{pmatrix} 1 - 2 \times \frac{1}{4} \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ 1 \end{pmatrix}$

$\nabla f(x_1) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}, \|\nabla f(x_0)\| = 1 > \varepsilon$

• 2) 第二次迭代

$d^1 = -\nabla f(x_1) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$x^2 = x^1 + k^1 d^1 = \begin{pmatrix} \frac{1}{2} \\ 1 \end{pmatrix} + k^1 \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ 1 + k^1 \end{pmatrix}$

• $g(k) = f(x^2) = -4(\frac{1}{2}) - 6 \times (1 + k^1) + 2 \times (\frac{1}{2})^2 + 2 \times (1 + k^1) \times \frac{1}{2} + 2 \times (1 + k^1)^2$

$\frac{dg(k)}{dk} = 4k^1 - 1$

$\bar{k}^1 = 1/4$

$\bar{k}^1 = 1/4, \quad d^1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$x^2 = \begin{pmatrix} \frac{1}{2} \\ 1 + \frac{1}{4} \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ \frac{5}{4} \end{pmatrix}$

$\nabla f(x^2) = \begin{pmatrix} -1/2 \\ 0 \end{pmatrix}, \quad \|\nabla f(x^2)\| = 0.25 < \varepsilon$

算法终止

问题: 对于全局而言最速下降方向未必是最快的。在一般情况下，当用最速下降法寻找极小点时，其搜索路径呈直角锯齿状（如下图），在开头几步，目标函数下降较快；但在接近极小点时，收敛速度长久不理想了。特别适当目标函数的等值 线为比较扁平的椭圆时，收敛就更慢了。

收敛速度影响因素：搜索的方向。。。

优化：在实用中常用最速下降法和其他方法联合应用，在前期使用最速下降法，而在接近极小值点时，可改用收敛较快的其他方法。

牛顿法

Step1 给定初始点 x⁰, 允许误差 ε>0.置 k=1 ,

Step2 若 $\|\nabla f(x^k)\| < \varepsilon$, 停止, 得解 x^k , 否则, 令

$x^{k+1} = x^k - \nabla^2 f(x^k)^{-1} \nabla f(x^k)$, k=k+1, 转 step2

例题

求 $f(x) = 4x_1^2 + 2x_1x_2 + 2x_2^2 + x_1 + x_2$ 的近似极小点。使用牛顿法。

$$= \begin{pmatrix} 8x_1 + 2x_2 + 1 \\ 2x_1 + 4x_2 + 1 \end{pmatrix}, H = \begin{pmatrix} 8 & 2 \\ 2 & 4 \end{pmatrix}$$

$$H^{-1} = \frac{1}{14} \begin{pmatrix} 2 & -1 \\ -1 & 4 \end{pmatrix}$$

$$x_{n+1} = x_n - H^{-1}(x_n) \nabla f(x_n)$$

$$= \begin{pmatrix} x_1^0 \\ x_2^0 \end{pmatrix} - \frac{1}{14} \begin{pmatrix} 2 & -1 \\ -1 & 4 \end{pmatrix} \begin{pmatrix} 8x_1 + 2x_2 + 1 \\ 2x_1 + 4x_2 + 1 \end{pmatrix}$$

$$= \begin{pmatrix} \frac{1}{14} \\ \frac{14}{3} \\ -\frac{14}{14} \end{pmatrix}$$

广义牛顿法—二阶导数法

- 二阶导数法（广义牛顿法）
 - 取初始点 $x^0 \in E^n$ ，允许误差 $\varepsilon > 0$.
 - 计算梯度方向 $d^p = -[\nabla^2 f(x^p)]^{-1} \nabla f(x^p)$
 - 进行一维搜索 $\min_k f(x^p + kd^p)$
 - $x^{p+1} = x^p + kd^p$
 - 精度判断为 $\|d^p\| \leq \varepsilon$

证明: d^p 为函数下降方向。即证 $\nabla f(x^p) \cdot d^p < 0$

$$\nabla^T f(x^p) \cdot d^p = \nabla^T f(x^p) \cdot -[\nabla^2 f(x^p)]^{-1} \nabla f(x^p) = -\nabla^T f(x^p) \cdot [\nabla^2 f(x^p)]^{-1} \nabla f(x^p)$$

可知当 $[\nabla^2 f(x^p)]^{-1}$ 正定时, $\nabla^T f(x^p) \cdot d^p < 0$

故只需 $f(x)$ 为凸函数, 即为下降方向。

二阶导数法对于二次函数可以一步达优。

• 例 4.5

$\min f(x) = x_1^2 + 25x_2^2, x^0 = (2,2)^T$, 精度为 0.01

解: $\nabla f(x) = \begin{pmatrix} 2x_1 \\ 50x_2 \end{pmatrix}$

$\nabla^2 f(x) = \begin{pmatrix} 2 & 0 \\ 0 & 50 \end{pmatrix} > 0$

$\nabla f(x^0) = \begin{pmatrix} 4 \\ 100 \end{pmatrix}, [\nabla^2 f(x)]^{-1} = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{50} \end{pmatrix}$

$\|\nabla f(x^0)\| = 50.04 > 0.01$

$d^0 = -[\nabla^2 f(x^0)]^{-1} \nabla f(x^0) = -\begin{pmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{50} \end{pmatrix} \begin{pmatrix} 4 \\ 100 \end{pmatrix} = -\begin{pmatrix} 2 \\ 2 \end{pmatrix}$

$\min f(x^0 + kd^0) = (2 - 2k)^2 + 25 \times (2 - 2k)^2 = 26 \times (2 - 2k)^2$

$\frac{df}{dk} = -104(2 - 2k) = 0 \rightarrow k = 1$

$x^1 = x^0 + kd^0 = (2,2)^T + (-2, -2)^T = (0,0)^T$

$\|\nabla f(x^1)\| = 0$, 故达最优。

问题: 1)局部收敛，初始点选择不当，可能会导致不收敛；2)牛顿法不是下降算法，当二阶 Hesse 阵非正定时，不能保证是下降方向；3)二阶 Hesse 阵必须可逆，否则算法将无法进行下去；4)对函数分析性质要求苛刻，计算量大，仅适合小规模优化问题。5)该方法需要求二阶导数，以及矩阵的逆，计算速度会很慢

二分法

优点：计算简单，方法可靠；对 f(x) 要求不高(只要连续即可)；收敛性总能得到保证；

缺点：可在大范围内求根，但收敛较慢,且不能求重根和复根，其收敛速度仅与一个以 1/2 为比值的等比级数相同，通常用于求根的初始近似值,而后在使用其它的求根方法。

FR 共轭梯度法

• **Fletcher-Reeves共轭梯度算法**

◦ 1：选取初始点 x^0 ，初始方向 $v^0 = -\nabla f(x^0)$

◦ 2：for $i = 1, \dots, n$

2.1: $x^i = x^{i-1} + \lambda_{i-1}v^{i-1}$, λ_{i-1} 取 $\min f(x^{i-1} + \lambda v^{i-1})$

2.2: $v^i = -\nabla f(x^i) + \frac{\|\nabla f(x^i)\|^2}{\|\nabla f(x^{i-1})\|^2}v^{i-1}$

3: $x^0 = x^n$.

• **例 4_7**

用FR共轭梯度法求：
 $\min f(x_1, x_2) = \frac{3}{2}x_1^2 + \frac{1}{2}x_2^2 - x_1x_2 - 2x_1, x^0 = (-2, 4)$
解：第1次迭代
 $\nabla f(x^0) = (3x_1 - x_2 - 2, x_2 - x_1)^T = (-12, 6)^T$
 $v^0 = -\nabla f(x^0) = (12, -6)^T$
 $x^1 = x^0 + \lambda v^0 = (-2, 4)^T + (12\lambda, -6\lambda)^T = (-2 + 12\lambda, 4 - 6\lambda)^T$
 $f(x^1) = \frac{3}{2}(-2 + 12\lambda)^2 + \frac{1}{2}(4 - 6\lambda)^2 - (-2 + 12\lambda)(4 - 6\lambda) - 2(-2 + 12\lambda)$
 $f'_\lambda(x^1) = 612\lambda - 180 = 0$
 $\lambda = \frac{5}{17}, x^1 = (\frac{26}{17}, \frac{38}{17})^T$

$$\nabla f(x^1) = (3x_1 - x_2 - 2, x_2 - x_1)^T = (\frac{6}{17}, \frac{12}{17})^T$$
$$d^1 = -\nabla f(x^1) + \frac{\|\nabla f(x^1)\|^2}{\|\nabla f(x^0)\|^2}d^0$$
$$= -(\frac{6}{17}, \frac{12}{17})^T + \frac{\|(\frac{6}{17}, \frac{12}{17})^T\|^2}{\|(-12, 6)^T\|^2} \cdot (\frac{6}{17}, \frac{12}{17})^T = (-\frac{90}{289}, \frac{210}{289})^T$$
$$x^2 = x^1 + \lambda d^1 = (\frac{26}{17}, \frac{38}{17})^T + (-\frac{90\lambda}{289}, \frac{210\lambda}{289})^T$$
$$\lambda = \frac{17}{10}$$
$$x^2 = (1, 1)^T$$
$$\nabla f(x^2) = 0$$

共轭梯度法特点：具有全局收敛性；收敛速度快（二次收敛）。对于正定二次函数，具有二次终结性；算法结构简单，计算量小，存储量小。（如 FR 法只要 3 个 n 维向量的存储空间）适用性：特别适用于大规模优化问题的求解。共轭梯度法需要计算梯度，这个过程很耗时

变尺度法-DFP 算子-拟牛顿

• **变尺度算法（DFP）**

◦ x^i 为搜索点， H_i 为H阵的近似。 $g^i = \nabla f(x^i)$

◦ 1：选取 x^0, H_0

◦ 2：for $i=0,1,\dots,n-1$

$x^{i+1} = x^i + \lambda_i v^i$,其中 $v^i = -H_i g^i$, λ_i 为一维搜索最优步长， $\min_{\lambda} f(x^i + \lambda v^i)$

3：令 $u^i = x^{i+1} - x^i$, $y^i = g^{i+1} - g^i$,

$H_{i+1} = H_i + A_i - B_i$, $A_i = \frac{u^i(u^i)^T}{(u^i)^T y^i}$, $B_i = \frac{H_i y^i (H_i y^i)^T}{(y^i)^T H_i y^i}$

◦ 4：判断精度，不满足则 $x^0 = x^n$,转2.

• **例 4_11**

用DFP方法求 $\min f(x) = \frac{1}{2}x^T A x$, $A = \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix}$, $x^0 = (\frac{10}{10})$,
 $H_0 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$
解： $\nabla f(x) = \begin{pmatrix} 3x_1 - x_2 \\ -x_1 + x_2 \end{pmatrix}$,
 $\nabla f(x^0) = (\frac{20}{0})^T, v^0 = -H_0 \nabla f(x^0) = -(\frac{20}{0})^T$
从 x^0 出发沿着方向 v^0 作一维搜索。
 $\min_{\lambda} f(x^0 + \lambda v^0)$
 $\varphi(\lambda) = f(x^0 + \lambda v^0) = 100 - 400\lambda + 600\lambda^2$
 $\frac{d\varphi}{d\lambda} = -400 + 1200\lambda = 0, \lambda_0 = 0.33$
 $x^1 = x^0 + \lambda_0 v^0 = (3, 34, 10)^T$

$$\nabla f(x^1) = (\frac{0.00}{6.66})^T, u^0 = \lambda_0 v^0 = -(\frac{6.6}{0})^T$$
$$y^0 = \nabla f(x^1) - \nabla f(x^0) = -(\frac{20}{-6.66})^T$$
$$A_1 = \frac{u^1(u^1)^T}{(u^1)^T y^1}, B_1 = \frac{H_0 y^1 (H_0 y^1)^T}{(y^1)^T H_0 y^1}$$
$$A_0 = \begin{bmatrix} 0.33 & 0 \\ 0 & 0 \end{bmatrix}, B_0 = -\begin{bmatrix} 0.9 & 0.3 \\ -0.3 & 0.01 \end{bmatrix}$$
$$H_{i+1} = H_i + A_i - B_i$$
$$H_1 = H_0 + A_0 - B_0 = \begin{bmatrix} 0.43 & 0.3 \\ 0.3 & 0.1 \end{bmatrix}$$

◦ $v^1 = -H_1 \nabla f(x^1) = -(\frac{2}{6})^T$

从 x^1 出发沿着方向 v^1 作一维搜索。
 $\min_{\lambda} f(x^1 + \lambda v^1)$
 $\lambda_1 = 5/3$
 $x^2 = x^1 + \lambda_1 v^1 = (-0, 0)^T$
 $H_2 = H_1 + A_1 + B_1 = \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 1.5 \end{bmatrix}$

Powell 算法


- 设有一组线性独立的向量 $\{v^i, i = 1, \dots, n\}$, x^0 为初始点。算法步骤为：
- 1：for $i=1, \dots, n$, 找到 $\min_{\lambda} f(y^{i-1} + \lambda v^i)$, 的 λ 值，递推推下一点
 $y^i = y^{i-1} + \lambda v^i$
- 2：for $i=1, \dots, n$, 使 $v^i = y^{i+1} - y^i$
- 3： $v^n = y^n - y^0$
- 4：找到 $\min_{\lambda} f(x^n + \lambda(x^n - x^0))$, 的 λ 值，替换 $x^0 = y^n + \lambda(y^n - y^0)$
- 5：达不到精度回到step1

• **例 4_9**

用powell方法求 $\min f(x) = (x_1 + x_2)^2 + (x_1 - 1)^2$,初始点 $x^0 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$, 初始搜索方向 $d^{(1,1)} = (1, 0)^T, d^{(1,2)} = (0, 1)^T$
解：第一轮迭代：
令 $y^{(1,1)} = x^0$, 从 $y^{(1,1)}$ 出发沿着方向 $d^{(1,1)}$ 作一维搜索。
 $\min_{\lambda} f(y^{(1,1)} + \lambda d^{(1,1)})$
 $y^{(1,1)} + \lambda d^{(1,1)} = (2, 1)^T + \lambda(1, 0)^T = (2 + \lambda, 1)^T$
 $\varphi(\lambda) = f(y^{(1,1)} + \lambda d^{(1,1)}) = (3 + \lambda)^2 + (1 + \lambda)^2$
 $\frac{d\varphi}{d\lambda} = 2(3 + \lambda) + 2(1 + \lambda) = 0, \lambda_1 = -2$
 $y^{(1,2)} = x^{(1,1)} + \lambda_1 d^{(1,1)} = (0, 1)^T$

从 $y^{(1,2)}$ 出发沿着方向 $d^{(1,2)}$ 作一维搜索。
 $\min_{\lambda} f(y^{(1,2)} + \lambda d^{(1,2)})$
 $\lambda_2 = -1, y^{(1,3)} = y^{(1,2)} + \lambda_2 d^{(1,2)} = (0, 0)^T$ **(坐标轮换结束)**
创建方向 $d^{(1,3)} = y^{(1,3)} - y^{(1,1)} = (-2, -1)^T$
求解 $\min_{\lambda} f(x^{(1,2)} + \lambda d^{(1,3)})$
 $\lambda_3 = -\frac{2}{13}, x^1 = y^{(1,3)} + \lambda_3 d^{(1,3)} = (\frac{4}{13}, \frac{2}{13})^T$
进入第2轮搜索：
初始点 $y^{(2,1)} = x^1 = (\frac{4}{13}, \frac{2}{13})^T$,
搜索方向为：
 $d^{(2,1)} = d^{(1,2)} = (0, 1)^T, d^{(2,2)} = d^{(1,3)} = (-2, -1)^T$

求解 $\min_{\lambda} f(y^{(2,1)} + \lambda d^{(2,1)})$
 $\lambda_1 = -\frac{6}{13}, y^{(2,2)} = y^{(2,1)} + \lambda_1 d^{(2,1)} = (\frac{4}{13}, -\frac{4}{13})^T$
求解 $\min_{\lambda} f(y^{(2,2)} + \lambda d^{(2,2)})$
 $\lambda_2 = -\frac{18}{169}, y^{(2,3)} = y^{(2,2)} + \lambda_2 d^{(2,2)} = (\frac{88}{169}, -\frac{34}{169})^T$
创建方向 $d^{(2,3)} = y^{(2,3)} - y^{(2,1)} = (\frac{36}{169}, -\frac{60}{169})^T$
求解 $\min_{\lambda} f(y^{(2,3)} + \lambda d^{(2,3)})$
 $\lambda_3 = \frac{9}{4}, x^2 = y^{(2,3)} + \lambda_3 d^{(2,3)} = (1, -1)^T$



• **关于powell算法的共轭方向**

◦ 定理：设 $f(x) = \frac{1}{2}x^T A x + b^T x + c$, A 为n阶正定阵。任取方向 d 和点 x^1, x^2 。从 x^1 出发沿方向 d 作一维搜索得极小点 y^1 , 从 x^2 出发沿方向 d 作一维搜索得极小点 y^2 , 则有 $y^2 - y^1$ 与方向 d 关于A共轭。

◦ 第一轮搜索方向：
 $d^{(1,1)} = (1, 0)^T, d^{(1,2)} = (0, 1)^T, d^{(1,3)} = (-2, -1)^T$

◦ 第二轮搜索方向：
 $d^{(2,1)} = (0, 1)^T, d^{(2,2)} = (-2, -1)^T, d^{(2,3)} = (\frac{36}{169}, -\frac{60}{169})^T$
沿方向 $d^{(1,3)}$ 得 x^1 , 沿方向 $d^{(2,2)}$ 得 $x^{(2,2)}$, 而 $d^{(2,3)} = x^{(2,2)} - x^{(2,0)}$, 故和方向 $d^{(2,2)}$ 共轭。

而 x^2 是沿共轭方向搜索得到的，因此必为极小点。

K-T 条件

◦ $\min f(x)$
 $s.t. \quad h_i(x) = 0 \quad i = 1, 2, \dots, r$
 $g_j(x) \leq 0 \quad j = 1, 2, \dots, n$

$$L(x, \lambda) = f(x) + \sum_{i=1}^r \mu_i h_i(x) + \sum_{j=1}^n \lambda_j g_j(x)$$
$$\begin{cases} \frac{\partial f}{\partial x_j}(x^*) + \sum_{i=1}^r \mu_i \frac{\partial h_i}{\partial x_j}(x^*) + \sum_{j=1}^n \lambda_j \frac{\partial g_j}{\partial x_j}(x^*) = 0 \\ h_i(x^*) = 0 \\ g_j(x^*) \leq 0 \\ (\lambda_j) g_j(x^*) = 0 \\ \lambda_j^* \geq 0 \end{cases}$$

• **例 6_8**

◦ 用KT条件解NLP问题

◦ $\min_x f(x) = (x_1 - 1)^2 + (x_2 - 2)^2$
 $s.t. \quad x_2 - x_1 = 1$
 $x_1 + x_2 \leq 2$
 $x_1, x_2 \geq 0$

解： $h_1(x) = -x_1 + x_2 - 1 = 0$
 $g_1(x) = x_1 + x_2 - 2 \leq 0$
 $g_2(x) = -x_1 \leq 0$
 $g_3(x) = -x_2 \leq 0$

$$L(x, \lambda) = f(x) + \sum_{i=1}^r \mu_i h_i(x) + \sum_{j=1}^n \lambda_j g_j(x)$$
$$L(x, \mu, \lambda) = (x_1 - 1)^2 + (x_2 - 2)^2 + \mu(-x_1 + x_2 - 1) + \lambda_1(x_1 + x_2 - 2) + \lambda_2(-x_1) + \lambda_3(-x_2)$$

根据KT条件有：

$$\frac{\partial L}{\partial x_1} = 2(x_1 - 1) - \mu + \lambda_1 - \lambda_2 = 0$$
$$\frac{\partial L}{\partial x_2} = 2(x_2 - 2) + \mu + \lambda_1 - \lambda_3 = 0$$
$$\lambda_1(x_1 + x_2 - 2) = 0$$
$$\lambda_2 x_1 = 0$$
$$\lambda_3 x_2 = 0$$
$$\lambda_1, \lambda_2, \lambda_3 \geq 0$$

讨论解的情况：

由 $h_1(x) = -x_1 + x_2 - 1 = 0$ 可设

情形I: $x_1 \neq 0, x_2 \neq 0$, 则: $\lambda_2 = 0, \lambda_3 = 0$

$$2(x_1 - 1) - \mu + \lambda_1 = 0$$
$$2(x_2 - 2) + \mu + \lambda_1 = 0$$
$$\lambda_1(x_1 + x_2 - 2) = 0$$
$$x_2 - x_1 = 1$$
$$x_1 + x_2 \leq 2$$
$$x_1, x_2 \geq 0$$

若 $\lambda_1 = 0$, 可得解 $\mu = 0, x_1 = 1, x_2 = 2$, 不满足 $x_1 + x_2 \leq 2$, 即非最优。

若 $\lambda_1 \neq 0$, 可得解 $\mu = 0, \lambda_1 = 1, x_1 = \frac{1}{2}, x_2 = \frac{3}{2}$, 满足各类条件。

情形II: $x_1 \neq 0, x_2 = 0$, 则: $\lambda_2 = 0, \lambda_3 \neq 0$, 得联立方程组：

$$2(x_1 - 1) - \mu + \lambda_1 = 0$$
$$2(0 - 2) + \mu + \lambda_1 = 0$$
$$\lambda_1(x_1 - 2) = 0$$
$$-x_1 = 1$$

可得解 $\mu = 0, \lambda_1 = 0, \lambda_3 = -4, x_1 = -1, x_2 = 0$, 不满足约束。

情形III: $x_1 = 0, x_2 \neq 0$, 则: $\lambda_2 \neq 0, \lambda_3 = 0$, 得联立方程组：

$$2(0 - 1) - \mu + \lambda_1 - \lambda_2 = 0$$
$$2(x_2 - 2) + \mu + \lambda_1 = 0$$
$$\lambda_1(x_1 - 2) = 0$$
$$x_2 - 1 = 0$$

可得解 $\mu = 0, \lambda_1 = 0, \lambda_2 = -4, x_1 = 0, x_2 = 1$, 满足约束。

坐标轮换法

• **坐标轮换算法步骤**

◦ 1：取 $x_1^1 \in E^n$, 置坐标轴方向：
 $e_1 = [1, 0, 0, \dots, 0]^T$
 $e_2 = [0, 1, 0, \dots, 0]^T$

◦ 令 $j = 1, k = 1, x_k^j = x_1^1$;
 $e_n = [0, 0, 0, \dots, 1]^T$

◦ 2：求单变量极值问题的最优解
 $\min_{\lambda} f(x_k^j + \lambda e_j) = f(x_k^j + \lambda_j e_j)$
 $x_k^{j+1} = x_k^j + \lambda_j e_j$

◦ 3：判断是否满足 $J = n$, 若 $J = n$, 转下一步, 否 $J++$, 转2.

◦ 4：检验是否满足收敛性判别准则
 $\|x_k^{j+1} - x_k^j\| < \varepsilon$, 否则令 $x_{k+1}^j = x_k^{j+1}, k++$, $j = 1$, 转2.

• **例5_1**

◦ 用坐标轮换法求 $\min f(x) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$
 $x^0 = (0, 3)^T, \varepsilon = 0.04$
解：取向量 $e_1 = (1, 0)^T, e_2 = (0, 1)^T$
 $x^0 + \lambda_1 e_1 = (\lambda_1, 3)^T$
 $f(x^0 + \lambda_1 e_1) = [\lambda_1 - 2]^4 + [\lambda_1 - 6]^2$

◦ 求 $\min f(x^0 + \lambda e_1)$

◦ $\frac{df(x^0 + \lambda_1 e_1)}{d\lambda_1} = 0 \rightarrow \lambda_1 = 3.13$
 $x_1^{(1)} = x^0 + \lambda_1 e_1 = \begin{bmatrix} 0 \\ 3 \end{bmatrix} + 3.13 \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 3.13 \\ 3 \end{bmatrix}$

$x_1^{(1)} = \begin{bmatrix} 3.13 \\ 3 \end{bmatrix}$ 出发, 沿 e_2 方向搜索, 求得 $x_1^{(2)}$

◦ $x_1^{(2)} = x_1^{(1)} + \lambda_2 e_2 = \begin{bmatrix} 3.13 \\ 3 + \lambda_2 \end{bmatrix}$

◦ $f(x_2^{(1)} + \lambda_2 e_2) = (1.13)^4 + (3.13 - 6 - 2\lambda_2)^2$

◦ 求 $\min f(x_2^{(1)} + \lambda_2 e_2)$

◦ $\frac{df(x_2^{(1)} + \lambda_2 e_2)}{d\lambda_2} = 0 \rightarrow \lambda_2 = -1.44$
 $x_1^{(2)} = x_1^{(1)} + \lambda_2 e_2 = \begin{bmatrix} 3.13 \\ 1.56 \end{bmatrix}$

优点是算法简单，计算量小。**其缺点**是计算效率低，对高维问题尤为突出。因此，坐标轮换法通常用于维数较低的优化问题（一般 n < 10）。对于可微函数，可能收敛于梯度为零的局部最优点。

步长加速法

- 1、给定初始步长 $\delta > 0$, 加速因子 $\alpha \geq 1$, 缩减率 $\beta \in (0, 1)$, 允许误差 $\varepsilon > 0$ 及初始迭代点 x^1 , 置 $y^1 = x^1, k = 1, j = 1$;
- 2、如果 $f(y^j + \delta e_j) < f(y^j)$, 令 $y^{j+1} = y^j + \delta e_j$, 转第4步; 否则转第3步。
- 3、如果 $f(y^j - \delta e_j) < f(y^j)$, 令 $y^{j+1} = y^j - \delta e_j$, 转第4步; 否则, 令 $y^{j+1} = y^j$, 转第4步。
- 4、如果 $j < n$, 则置 $j = j + 1$, 转第2步; 否则, 转第5步;
- 5、如果 $f(y^{n+1}) < f(x^k)$, 则转第6步; 否则, 转第7步;
- 6、令 $x^{k+1} = y^{n+1}, y^1 = x^{k+1} + \alpha(x^{k+1} - x^k) = (1 + \alpha)x^{k+1} - \alpha x^k$, 置 $k = k + 1, j = 1$, 转第2步;
- 7、 $\delta = \beta \delta, y^1 = x^k, x^{k+1} = x^k$, 置 $k = k + 1, j = 1$, 转第2步。

• **例5_2**

- 用步长加速法求 $\min f(x) = (1-x_1)^2 + 5(x_2-x_1^2)^2$
 $x^1 = (2.0)^T$, 初始步长 $\delta = 0.5$, 加速因子 $\alpha = 1$, 缩减率 $\beta = 0.5$, 坐标方向 $e_1 = (1.0)^T, e_2 = (0.1)^T$
解: 先在 x^1 周围进行探测移动, 令 $y^1 = (2.0)^T$, 探测情况如下:

$$f(y^1) = 81, \quad y^1 + \delta e_1 = \begin{bmatrix} 2 \\ 0 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{5}{2} \\ 0 \end{bmatrix}$$

- $f(y^1 + \delta e_1) = 197 \frac{9}{16} > f(y^1)$, 故失败。

$$y^1 - \delta e_1 = \begin{bmatrix} 2 \\ 0 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{3}{2} \\ 0 \end{bmatrix}$$

- $f(y^1 - \delta e_1) = 25 \frac{9}{16} < f(y^1)$, **成功**。

- 因此, 令 $y^2 = y^1 - \delta e_1 = \begin{bmatrix} \frac{3}{2} \\ 0 \end{bmatrix}$, 从 y^2 出发, 沿 e_2 探测情况如下:

$$y^2 + \delta e_2 = \begin{bmatrix} \frac{3}{2} \\ 0 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{3}{2} \\ \frac{1}{2} \end{bmatrix}$$

- $f(y^2 + \delta e_2) = 15 \frac{9}{16} < f(y^2)$, **成功**。

$$y^2 - \delta e_2 = \begin{bmatrix} \frac{3}{2} \\ 0 \end{bmatrix} - \frac{1}{2} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{3}{2} \\ -\frac{1}{2} \end{bmatrix}$$

- 因此, 令 $y^3 = y^2 + \delta e_2 = \begin{bmatrix} \frac{3}{2} \\ \frac{1}{2} \end{bmatrix}$ 。

- 第一轮探测完成后, 由于 $f(y^3) < f(y^1)$, 因此得到第2个基点
 $x^2 = y^3 = \begin{bmatrix} \frac{3}{2} \\ \frac{1}{2} \end{bmatrix}$, 再沿方向 $x^2 - x^1$ 进行**模式移动**, 令:

$$y^1 = x^2 + \alpha(x^2 - x^1) = 2x^2 - x^1 = 2 \begin{bmatrix} \frac{3}{2} \\ \frac{1}{2} \end{bmatrix} - \begin{bmatrix} 2 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

- 模式移动后, 立即从得到的点 y^1 出发, **进行第2轮探测移动**。探测情况如下:

- 先沿 e_1 探测, 这时有:

$$f(y^1) = 0, \quad y^1 + \delta e_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \frac{1}{2} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{3}{2} \\ 1 \end{bmatrix}$$

- $f(y^1 + \delta e_1) = 8 \frac{1}{16} > f(y^1)$, 失败

$$y^1 - \delta e_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{2} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ 1 \end{bmatrix}$$

- $f(y^1 - \delta e_1) = 3 \frac{1}{16} > f(y^1)$, 失败;

- 由于沿 e_1 的**正反向探测均失败**, 故令 $y^2 = y^1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

- 从 y^2 出发沿 e_2 探测的情况是:

$$f(y^2 + \delta e_2) = \frac{5}{4} > f(y^2)$$
, 失败

$$f(y^2 - \delta e_2) = \frac{5}{4} > f(y^2)$$
, 失败;

- 由于沿 e_2 的正反向探测均失败, 故令 $y^3 = y^2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

- 比较在 y^3 和基点 x^2 处的函数值, 由于 $f(y^3) = 0 < f(x^2) = 15 \frac{9}{16}$, 表明此次模式移动是成功的, 因此得到新的基点:
 $x^3 = y^3 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

- 从 x^3 出发沿方向 $x^3 - x^2$ 进行模式移动。令:

$$y^1 = x^3 + \alpha(x^3 - x^2) = 2x^3 - x^2 = (\frac{1}{2}, \frac{3}{2})^T$$

- 然后, 从 y^1 出发, 进行探测移动。做下去就会发现此次模式移动仍失败。因此退回到基点 x^3 。减小步长, 令: $\delta = \beta\delta = \frac{1}{4}\delta$

- 再从 $y^1 = x^3$ 开始, 依次沿 e_1, e_2 探测。我们还会发现, 在 x^3 周围的探测移动也是失败的, 必须继续缩减步长。继续下去, 必能得出结论, **x^3 是局部最优解**。

- 事实上, 用解析方法容易求得 x^3 是此问题的最优解。

可行方向法

- 1: 计算 $\nabla f(x^p), \nabla g_i(x^p), i = 1, \dots, m$
- 2: 解线性规划问题 $\max_{d^p} x_0$
$$\begin{aligned} s.t. \quad & x_0 + (\nabla f(x^p), d^p) \leq 0 \\ & x_0 + (\nabla g_i(x^p), d^p) \leq -g_i(x^p) \quad i = 1, \dots, m \\ & (\nabla g_i(x^p), d^p) \leq 0 \quad i = 1, \dots, m \text{ (可如此简化)} \\ & |d^p| \leq 1 \end{aligned}$$
- 3: 当 $x_0 = 0$ 时停止
- 4: 求得合适步长 $k_p > 0$, 并保证 $\min f(x^p + k_p d^p)$

• **例 7_5**

- $\min f(x) = x_1^2 + 2x_2^2$ $X_0 = (0.85, 3.15)$
- s.t. $x_1 + x_2 \geq 4$

$$\begin{aligned} & \max_{d^p} x_0 \\ & s.t. \quad x_0 + (\nabla f(\bar{x}), d) \leq 0 \\ & \quad (\nabla g(\bar{x}), d) \leq 0 \\ & \quad |d_1| \leq 1, |d_2| \leq 1 \end{aligned}$$

$$\nabla f(x) = \begin{pmatrix} 2x_1 \\ 4x_2 \end{pmatrix} = \begin{pmatrix} x_1 \\ 2x_2 \end{pmatrix}, \nabla f(\bar{x}) = \begin{pmatrix} 0.85 \\ 6.30 \end{pmatrix}, \text{归一化为: } \begin{pmatrix} 0.134 \\ 0.991 \end{pmatrix}$$

$$\nabla g(\bar{x}) = \begin{pmatrix} -1 \\ -1 \end{pmatrix}, \text{归一化为: } \begin{pmatrix} -0.707 \\ -0.707 \end{pmatrix}$$

$$\begin{aligned} & \max_{d^p} x_0 \\ & s.t. \quad x_0 + 0.134d_1 + 0.991d_2 \leq 0 \\ & \quad -0.707d_1 - 0.707d_2 \leq 0 \\ & \quad |d_1| \leq 1, |d_2| \leq 1 \end{aligned}$$

可得: $d_2 = -0.5, d_1 = 1, x_0 = 0.357$

- 再考查一个点: $\bar{x} = \begin{pmatrix} 2.667 \\ 1.333 \end{pmatrix}$

$$\nabla f(x) = \begin{pmatrix} 2x_1 \\ 4x_2 \end{pmatrix} = \begin{pmatrix} x_1 \\ 2x_2 \end{pmatrix}, \nabla f(\bar{x}) = \begin{pmatrix} 2.667 \\ 2.666 \end{pmatrix}, \text{归一化为} \begin{pmatrix} 0.707 \\ 0.707 \end{pmatrix}$$

$$\nabla g(\bar{x}) = \begin{pmatrix} -1 \\ -1 \end{pmatrix}, \text{归一化为: } \begin{pmatrix} -0.707 \\ -0.707 \end{pmatrix}$$

$$\begin{aligned} & \max_{d^p} x_0 \\ & s.t. \quad x_0 + 0.707d_1 + 0.707d_2 \leq 0 \\ & \quad -0.707d_1 - 0.707d_2 \leq 0 \\ & \quad |d_1| \leq 1, |d_2| \leq 1 \\ & \quad d_1 = 1, d_2 = -1, x_0 = 0 \end{aligned}$$

刺绣法

- **“刺绣法” (hemstitching) 算法**
- $\min f(x), \quad s.t. \quad g(x) \geq 0$ 已知: x^0, h, δ , 求 x^*
- step1. 求归一化的 $\nabla f(x), \nabla g(x)$
- step2. while($\|x^{p+1} - x^p\| > \delta$)
 - if x^p 在可行域内部, 则: $x^{p+1} = x^p - h\nabla f(x^p)$
 - if x^p 在可行域外部, 则: $x^{p+1} = x^p + h\nabla g(x^p)$

• **例 7_1**

- $\min f(x) = x_1^2 + 2x_2^2$
- s.t. $x_1 + x_2 \geq 4$
- 设初始点为 $(1.4, 5)$, 固定步长为1.0
- 归一化后的梯度为:

$$\nabla f(x) = \frac{1}{\sqrt{4x_1^2 + 16x_2^2}} \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix}, \nabla g(x) = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

- if x^p 在可行域内部, 则: $x^{p+1} = x^p - 1.0\nabla f(x^p)$
- if x^p 在可行域外部, 则: $x^{p+1} = x^p + 1.0\nabla g(x^p)$

$$(1.4, 5) \rightarrow (0.89, 3.5) \rightarrow (0.76, 2.50) \rightarrow (1.47, 3.21) \rightarrow (1.05, 2.30) \rightarrow (1.76, 3.01) \rightarrow (1.37, 2.10) \rightarrow (2.08, 2.81)$$

改进刺绣法

- **改进的刺绣法**
- 算法在处理出可行域时, 同时考虑目标函数优化和可行域偏差。具体实现是:
- $x^{p+1} = x^p + k_p d^p$
- if x^p 在可行域内部, 则: $d^p = -\frac{\nabla f(x^p)}{\|\nabla f(x^p)\|}$
- if x^p 在可行域外部, 则:
$$d^p = -\frac{\nabla f(x^p)}{\|\nabla f(x^p)\|} + \sum g_i(x) \text{ violate at } x^p \frac{\nabla g_i(x^p)}{\|\nabla g_i(x^p)\|}$$
- 当两个梯度方向正好相反时, 效率会低。

• **例 7_2**

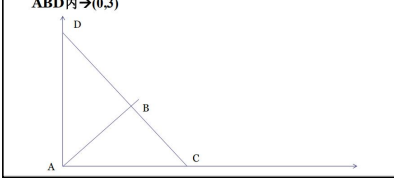
- 写出下面规划问题的刺绣法的递推迭代公式:
- $\min f(x) = x_1^2 + x_2^2$
- s.t. $3x_1 + 2x_2 \geq 6$
- $x_1, x_2 \geq 0$
- 起始点: (2.3) , 步长为 k_p

- $\nabla f(x) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}, \nabla g(x) = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$
- $x^{p+1} = \begin{cases} x^p - \frac{k_p}{\sqrt{4x_1^2 + 4x_2^2}} \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix} \\ x^p + \frac{k_p}{\sqrt{13}} \begin{bmatrix} 3 \\ 2 \end{bmatrix} \end{cases}$
- $x^* = \begin{pmatrix} 18 \\ 13 \end{pmatrix} \frac{1}{13}$

• **例 7_3**

- $\max f(x) = x_1^2 + x_2^2$
- s.t. $6 - 3x_1 - 2x_2 \geq 0$
- $x_1, x_2 \geq 0$
- 起始点: $(0, 0)$

- $\nabla f(x) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix} \rightarrow \nabla f(x_0) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$
- 若出发点在 $x_2 = \frac{2}{3}x_1 \rightarrow (\frac{18}{13}, \frac{12}{13})$; 若在ABC内 $\rightarrow (2, 0)$; 在ABD内 $\rightarrow (0, 3)$



罚函数算法-内点法

- **内点罚函数算法步骤**
- 1. 给定初始点 x^0 , 罚参数 $\{K_i\}$, 缩小系数 δ , 精度 $\varepsilon > 0$, 置 $\varepsilon_0 = 1$
- 2. 构造罚函数 $F(x, K) = f(x) + K \sum_{i=1}^m \frac{1}{g_i(x)}$
- 3. 用某种无约束非线性规划, 以 x^{m-1} 为初始点求解 $F(x, K)$
- 4. 设最优解为 x^m , 若 x^m 满足终止条件, 结束, 否则 $m++$, 转2.

$$\{K_i\} \text{ 的一般选法: 先选定一个初始常数 } K_1 \text{ 和一个比例系数 } \delta < 1, \text{ 则 } K_i = K_1 \delta^{i-1}$$

• **例 7_10**

- 用内点法求 $\min f(x) = x_1^2 + x_2^2$
- s.t. $x_1 + x_2 - 1 \geq 0$
 $2x_1 - x_2 - 2 \geq 0$
 $x_1, x_2 > 0$
- 初始点为 $[3, 1], K_1 = 8, \delta = 0.5$
- 解: $P(x, K) = f(x) + \sum_{i=1}^m K_i / [g_i(x)]$
 $= x_1^2 + x_2^2 + k_1 / (x_1 + x_2 - 1) + k_1 / (2x_1 - x_2 - 2) + k_1 / x_1 + k_1 / x_2$
- 使用坐标轮换法求解此无约问题得到 $x' = \begin{pmatrix} 2.76 \\ 1.43 \end{pmatrix}$
精度为0.49, 继续迭代, 令 $K_1 = K_1 \times \delta = 4$, 进入下一轮...

罚函数算法-外点法

- **外点罚函数算法步骤**
- 1. 给定初始点 x^0 , 罚参数 $\{K_i\}$, 精度 $\varepsilon > 0$, 置 $m = 1$
- 2. 构造罚函数 $F(x, K) = f(x) + K \|g(x)\|^2$
- 3. 采用无约束非线性规划, 以 x^{m-1} 为初始点求解 $F(x, K)$
- 4. 设最优解为 x^m , 若 x^m 满足终止条件, 结束, 否则 $m++$, 转2.

$$\{K_i\} \text{ 的一般选法: 先选定一个初始常数 } K_1 \text{ 和一个比例系数 } \delta \geq 2, \text{ 则 } K_i = K_1 \delta^{i-1}$$

$$\text{终止条件可选 } \|x^{m+1} - x^m\|^2$$

• **例 7_8**

- 用外点法求 $\min f(x) = \frac{1}{2}x_1^2 + \frac{1}{4}x_2^2$
- s.t. $x_1 + x_2 = 1$
- 初始点为 $[0, 0], K_1 = 0.05, \delta = 2$
- 解: $P(x, K) = f(x) + \sum_{i=1}^m K_i [h_i(x)]^2$
 $= \frac{1}{2}x_1^2 + \frac{1}{4}x_2^2 + K_1 [x_1 + x_2 - 1]^2$
- 使用牛顿法求此无约多维优化问题: $x' = \begin{pmatrix} 1/13 \\ 2/13 \end{pmatrix}$
 $\|x' - x^m\| = 0.17$ 循环继续...
- $K_1 = K_1 \delta = 0.05 \times 2 = 0.1 \dots$
- $x^* = \begin{pmatrix} 0.329 \\ 0.658 \end{pmatrix}$

• **例 7_9**

- 用外点法求 $\min f(x) = x_1^2 - x_1x_2 + x_2 - x_1 + 1$
- s.t. $2x_1 + 3x_2 - 9 = 1$
 $x_1^2 + x_2^2 - 6 \geq 0$
 $x_1, x_2 > 0$
- 初始点为 $[2.2], K_1 = 0.05, \delta = 2$

$$P(x, K) = f(x) + \sum_{i=1}^m K_i [h_i(x)]^2 + \sum_{i=1}^m K_i [\min(0, g_i(x))]^2$$

代码—黄金分割法

```
while b-a>delta
    k=k+1;
    L=0.618*(b-a);
    x1=b-L;
    x2=a+L;
    f_x1=subs(fx,findsym(fx),x1);
    f_x2=subs(fx,findsym(fx),x2);
    if f_x1>f_x2
        a=x1;
    else
        b=x2;
    end
    x0=(a+b)/2;
    f_x0=subs(fx,findsym(fx),x0);
disp(sprintf('k=%d,[%.4f-%.4f],x1=%.2f,x2=%.2f,fx1=%.2f,fx2=%.2f,delta=%.2f,x=%.4f,fx=%.4f\n',k,a,b,x1,x2,eval(f_x1),eval(f_x2),abs(b-a),x0,eval(f_x0)));
end
```

代码—牛顿法

```
while norm(g1) > e
    x0=x0-inv(g2)*g1;
    g1=subs(df,{x1,x2},{x0(1,1),x0(2,1)});
    g2=subs(ddf,{x1,x2},{x0(1,1),x0(2,1)});

    k=k+1;
    fprintf('迭代次数 :%d,x1=%f,x2=%f\n',k,eval(x0(1,1)),eval(x0(2,1)));
end
```

代码—坐标轮换法

```
while norm(x)>e
    x00=x0;
    x01=x0+t1*e1;
    fx1=(x01(1,1)-2)^4+(x01(1,1)-2*x01(2,1))^2;
    df1=diff(fx1,'t1');
    t10=vpa(solve(df1),2);
    t10=t10(t10==real(t10));
    x0=x0+t10*e1;
    x02=x0+t2*e2;
    fx2=(x02(1,1)-2)^4+(x02(1,1)-2*x02(2,1))^2;
    df2=diff(fx2,'t2');
    t20=vpa(solve(df2),2);
    t20=t20(t20==real(t20));
    x0=x0+t20*e2;
```

```
x=x0-x00;
k=k+1;
fprintf('迭代次数 :%d,x1=%f,x2=%f\n',k,eval(x0(1,1)),eval(x0(2,1)));
End
```

代码一步长加速法

```
for i=1:maxIter
    if i==1
        X(i,:)= [0,3]; y1=X(i,:);
    end
    fy1=subs(f,{x1,x2},{y1(1),y1(2)});
    y1pe1=y1+delta*e1;
    if
        subs(f,{x1,x2},{y1pe1(1),y1pe1(2)})<fy1
            y2=y1pe1;
        fy2=subs(f,{x1,x2},{y1pe1(1),y1pe1(2)});
    else
        y2=y1;fy2=fy1;
    end
    y1me1=y2-delta*e1;
    if
        subs(f,{x1,x2},{y1me1(1),y1me1(2)})<fy2
            y3=y1me1;
        fy3=subs(f,{x1,x2},{y1me1(1),y1me1(2)});
    else
        y3=y2;fy3=fy2;
    end
    y1pe2=y3+delta*e2;
    if
        subs(f,{x1,x2},{y1pe2(1),y1pe2(2)})<fy3
            y4=y1pe2;
        fy4=subs(f,{x1,x2},{y1pe2(1),y1pe2(2)});
    else
        y4=y3;fy4=fy3;
    end
    y1me2=y4-delta*e2;
    if
        subs(f,{x1,x2},{y1me2(1),y1me2(2)})<fy4
            y5=y1me2;
        fy5=subs(f,{x1,x2},{y1me2(1),y1me2(2)});
    else
        y5=y4;fy5=fy4;
    end
    X(i+1,:)=y5;
    y1=X(i+1,:)+alpha*(X(i+1,:)-X(i,:));
```

```
if X(i+1,:)==X(i,:)
    delta=delta*beta;
end
k=k+1;
disp(['探测次数 :',num2str(k),'x1=',num2str(X(i,1)),',x2=',num2str(X(i,2))]);
end
```

代码—斐波那契

```
%先确定 N
F=ones(1,2);
n=2;
while 1
    n=n+1;
    F(n)=F(n-1)+F(n-2);

    if F(n)>=Fn
        break;
    end

end

L1=b-a;
L2=L1*F(n-1)/F(n);

x1=b-L2;
x2=a+L2;

for k=1:n-1

    fx1=subs(fx,findsym(fx),x1);

    fx2=subs(fx,findsym(fx),x2);

    if fx1<fx2

        b=x2;x2=x1;x1=a+b-x2;

    elseif fx1==fx2

        a=x1;b=x2;

    else

        a=x1;x1=x2;x2=b-(x1-a);

    end

    x0=(x1+x2)/2;

    f_x0=subs(fx,findsym(fx),x0);

disp(sprintf('k=%d,[%.2f,%.2f],x=%.4f,fx=%.4f\n',k,a,b,x0,eval(f_x0)));

end
```